

分类号: TP311.5

单位代码: 10335

密 级: 无

学 号: 22251326

浙江大学

硕士学位论文



中文论文题目: 基于可微渲染的双目视频驱动人脸
动画生成

英文论文题目: **Binocular Video-Driven Facial
Animation Based on Differentiable
Rendering**

申请人姓名: 刘佳航

指导教师: 吴鸿智

专业学位类别: 电子信息

专业学位领域: 人工智能

所在学院: 软件学院

论文提交日期 2025 年 6 月 6 日

摘要

数字人一直是图形学的热点研究方向，其不仅拥有真人的容貌，还支持制作动画、重新光照等编辑能力，将人物的面部表情在其数字人上精准重演，并支持数字人的各种后期编辑，成为近年的一个热点研究课题。现有方法难以在日常的复杂光照条件变化下精准还原人脸的各种极端表情和细节神态，使得数字人重演人脸动画暂时未能得到广泛应用，本文重点针对提高表情还原度和适应复杂光照展开了研究。

本文设计了一种三阶段可微渲染框架，由粗到细地对人脸表情和漫反射贴图进行深度优化，并建模了一种参数化的贴图来缓解复杂人脸材质带来的域差异，克服复杂光照变化带来的影响，同时结合超细粒度的肌肉动力学建模，设计了一套可构建贴合本人表情特征的骨骼绑定的方法，该绑定可以完成平滑、合理、无瑕疵的表情插值，其表示空间可从该人的细节神态覆盖至咧嘴、狰狞等各种极端表情，拉高了表情还原度的上限。在三阶段可微渲染框架之前，为使可微渲染获得良好的初值，本文将双目视频通过预训练的人脸双目匹配神经网络得到人脸四千余组匹配，通过立体视觉得到对应的几何点深度和精确坐标，以优化出准确的刚体变换和大致表情，确保了每帧的可微渲染都可快速收敛。

实验证明，本文方法可高质量还原视频中人物的各种极端表情和细节神态，生成的动画不仅与原图有极高的相似度，且支持重新光照、切换视角、后期编辑等工业界应用，相比于现有的基于三维模型的面部表情捕捉方法，本文方法对各种表情尤其是极端表情的还原度存在着显著优势，每帧的信噪比接近 38dB，也为在工业界落地提供了可能。

关键词： 人脸动画，人脸建模，可微渲染，增强现实

Abstract

Digital humans have always been a focal research direction in computer graphics, characterized by their photorealistic appearance and editing capabilities such as animation production and relighting. The precise reenactment of facial expressions on digital humans with post-production editability has emerged as a prominent research topic in recent years. However, existing methods struggle to accurately reconstruct extreme expressions and subtle facial nuances under complex daily illumination variations, limiting the widespread application of digital human facial animation. This paper specifically addresses the challenges of enhancing expression fidelity and adapting to complex lighting conditions.

We propose a three-stage differentiable rendering framework that progressively optimizes facial expressions and diffuse texture maps from coarse to fine levels. A parameterized texture modeling approach is developed to resolve domain gap caused by complex facial materials, effectively overcoming illumination variations. Integrating ultra-fine-grained muscle dynamics modeling, we devise a skeletal rigging method that constructs perfectly customized expression features. This rigging enables smooth, physically plausible, and artifact-free expression interpolation, with a representation space covering both subtle expressions and extreme manifestations like wide grins and grimaces, thereby elevating the upper bound of expression fidelity. Prior to the three-stage rendering framework, to ensure good initialization for differentiable rendering, we process binocular videos through a pre-trained facial stereo matching neural network to obtain over 4,000 facial feature correspondences. These are used to derive geometric depth information and precise coordinates through stereo vision, optimizing rigid transformations and coarse expressions to guarantee rapid convergence of per-frame differentiable rendering.

Experimental results demonstrate that our method achieves high-fidelity reenactment of various extreme expressions and subtle facial details from input videos. The generated animations not only exhibit exceptional similarity to source materials but

also support industry applications including relighting, viewpoint switching, and post-production editing. Compared with existing 3D model-based facial capture methods, our approach shows significant advantages in reenacting diverse expressions, particularly extreme ones, while maintaining stable PSNR near 38 dB, demonstrating strong potential for industrial implementation.

Keywords: Facial animation, Facial modeling, Differentiable rendering, Augmented reality

目录

摘要	i
Abstract.....	ii
图目录	III
表目录	V
缩略词表	VI
第 1 章 绪论	1
1.1 课题背景	1
1.2 本文工作	4
1.3 篇章结构	6
第 2 章 相关工作	7
2.1 人脸建模	7
2.2 人脸反射属性	9
2.3 人脸动画绑定方法	13
2.3.1 三维混合形状方法	13
2.3.2 骨骼绑定方法	14
2.3.3 隐式表达方法	17
2.4 面部表情捕捉	17
2.4.1 基于单目摄像头的方法	17
2.4.2 基于 RGBD 摄像头的方法	18
2.4.3 基于多视角的方法	19
2.5 本文方法论框架	21
2.6 本章小结	22
第 3 章 逐层级计算的面部骨骼绑定	23
3.1 算法概述	23
3.2 基于逐层级优化的人脸表情空间计算	25
3.2.1 基于 MetaHuman 模板构建初始绑定	25
3.2.2 逐层级计算的关节求解器	27
3.2.3 GPU 加速的 Dogleg 算法	32
3.3 结果分析	35
3.4 本章小结	37
第 4 章 基于可微渲染及立体视觉的人脸动画	39
4.1 硬件及数据准备	39
4.2 算法概述	42
4.3 双目几何约束的初值估计	43
4.3.1 人脸双目匹配神经网络	43
4.3.2 视差重建点云	47

4.3.3 基于点云优化刚体变换及表情系数	49
4.4 三阶段可微渲染	52
4.4.1 光照建模	52
4.4.2 面部表情求解	57
4.5 本章小结	62
第 5 章 实验结果与分析	63
5.1 实验配置	63
5.2 效果评估	65
5.3 消融实验	73
5.4 本章小结	77
第 6 章 总结与展望	78
参考文献	80
作者简历	85
致谢	86

图目录

图 1.1	《阿凡达》电影拍摄片场	1
图 1.2	本文表情还原、重光照及切换视角效果	4
图 2.1	重建系统示意图	7
图 2.2	微表面模型	9
图 2.3	二层皮肤介质模型 ^[31]	11
图 2.4	Blendshape 表情基插值	13
图 2.5	MetaHuman 的数字人生成结果展示	14
图 2.6	MetaHuman 人脸绑定及其 UI 控制器	15
图 2.7	Rackovic 等人的 blendshape 聚类 ^[53]	16
图 2.8	早期单目面部表情捕捉方法	17
图 2.9	最新单目面部表情捕捉方法	18
图 2.10	Weise 等人驱动非真实感头像 ^[18]	19
图 2.11	MetaHuman Animator 视频采集设备及处理时界面	19
图 2.12	Cao 等人方法的原图、结果、几何损失和去光照的结果对比 ^[1]	20
图 2.13	Huang 等人使用 LightStage 进行的面部表情捕捉结果 ^[13]	20
图 2.14	基于三级联动的理论框架	21
图 3.1	面部绑定算法流程图	24
图 3.2	MetaHuman 多层级骨骼系统	25
图 3.3	表层关节分布（蓝色圆球为关节）	26
图 3.4	模型包裹示意图	26
图 3.5	LOD4 的关节分布（左图）与 LOD0 的关节分布（右图）	28
图 3.6	不同 LOD 的表情细节丰富程度	29
图 3.7	信赖域与 Dogleg 步长	34
图 3.8	本章算法生成绑定的插值结果	35
图 3.9	通过 Maya 使用本章绑定进行表情调整	36
图 3.10	人脸表情空间计算前后的对比	36
图 4.1	双目视频采集设备	39
图 4.2	16 张标定板拍摄图	40
图 4.3	算法概览图	42
图 4.4	LOFTR 网络结构 ^[9]	43
图 4.5	人脸双目匹配结果	44
图 4.6	预训练模型匹配结果	45
图 4.7	简易立体视觉采集重建设备	45
图 4.8	微调后模型的匹配结果	46
图 4.9	采集时和录制视频时的中性表情的重建结果	47
图 4.10	ICP 配准采集的中性表情的点云与视频的中性表情的点云	48
图 4.11	原视频帧与光照适应阶段可微渲染最终渲染结果对比	49

图 4.12	视频帧与采集时光照、位姿、皮肤状态、相机色彩差异对比	49
图 4.13	人脸特征点位置示意	50
图 4.14	本节优化得到的模型与真实模型的对比	51
图 4.15	本节优化得到的模型与真实模型对比的色温图	51
图 4.16	前四阶球谐基函数示意图	52
图 4.17	将 T 贴图在人脸上渲染的结果重光照	53
图 4.18	T 贴图与采集重建的漫反射贴图的差异	54
图 4.19	两个视角亮部区域的对比	55
图 4.20	三阶段可微渲染流程图	55
图 4.21	人脸区域分割遮罩	57
图 4.22	求解环境光步骤	57
图 4.23	可微渲染中间结果	58
图 4.24	眼球解算贴图	58
图 4.25	解算最终结果	59
图 4.26	算法对于光照变化的适应展示	59
图 5.1	采集重建设备	61
图 5.2	参与实验的所有角色	62
图 5.3	极端表情和细节神态原图与还原结果对比	63
图 5.4	连续帧原图与还原结果对比	64
图 5.5	生成资产的后期编辑特性	65
图 5.6	MICA、Animator 与本文算法结果的对比	66
图 5.7	几何还原度展示	69
图 5.8	动画序列在 Maya 中的编辑	70
图 5.9	挤眼的人脸表情空间计算消融实验	71
图 5.10	三阶段可微渲染消融实验	72
图 5.11	最大迭代轮数设计原则	73
图 5.12	采样率设计原则	73
图 5.13	人脸双目立体视觉消融实验	73

表目录

表 3.1	不同 LOD 层级的关节数量及优化目标	28
表 3.2	Dogleg 与 LM 算法的优化效率对比	33
表 3.3	优化表情终值与采集表情误差	37
表 5.1	实验运行环境	61
表 5.2	前五帧执行时间（单位：秒）	65
表 5.3	PSNR、SSIM 和 LPIPS 的通用标准	67
表 5.4	动画重演精度数值对比	68
表 5.5	几何还原度数值对比	70

缩略词表

缩略词	英文全称	中文翻译	首次出现页码
PSNR	Peak Signal-to-Noise Ratio	峰值信噪比	i (中文摘要)
RGB	Red Green Blue	红、绿、蓝	3 (第一章)
BRDF	Bidirectional Reflective Distribution Function	双向反射分布函数	9 (第二章)
RBF	Radial Basis Function	径向基函数	14 (第二章)
UI	User Interface	用户界面	15 (第二章)
SSDR	Smooth Skinning Decomposition with Rigid Bones	线性蒙皮分解	16 (第二章)
CNN	Convolutional Neural Network	卷积神经网络	18 (第二章)
RGBD	Red Green Blue and Depth	红、绿、蓝、深度	19 (第二章)
N-ICP	Nonrigid Iterative Closest Point	非刚性迭代最近点配准	23 (第三章)
MVC	Mean Value Coordinates	均值重心坐标	24 (第三章)
LOD	Level of Details	细节等级	24 (第三章)
ICP	Iterative Closest Point	迭代最近点算法	44 (第四章)
SVD	Singular Value Decomposition	奇异值分解	44 (第四章)
SLAM	Simultaneous Localization And Mapping	即时定位与地图构建	44 (第四章)
spp	Samples Per Pixel	每像素采样数	53 (第五章)
FPS	Frames Per Second	每秒帧数	58 (第五章)
SSIM	Structural Similarity Index Measure	结构相似性指数	63 (第五章)
LPIPS	Learned Perceptual Image Patch Similarity	基于学习的感知图像块相似性	63 (第五章)

第1章 绪论

1.1 课题背景

近年来，面部表情捕捉技术作为计算机图形学与计算机视觉领域的重要研究方向，持续受到学术界与工业界的广泛关注。目前主流的高精度表情捕捉方案仍依赖于面部显式标记点的设置（如图 1.1 《阿凡达》电影拍摄现场所示），并且在后期处理阶段依赖大量人工干预。若能突破显式标记点的限制，通过录制的视频端到端生成三维高保真面部动画数据，不仅有望大幅降低影视动画制作成本，更能为下一代虚拟现实/增强现实社交应用提供关键技术支撑，显著提升虚拟人际交互的沉浸感与真实感。然而，在复杂光照条件下实现精细面部表情（如眼神交流、唇部微表情、眨眼动作等）的精准迁移，仍是该领域亟待解决的核心挑战^[1]。



图 1.1 《阿凡达》电影拍摄片场

该技术在实践过程中有三大技术难点：第一是构建出完美贴合本人表情特征的面部绑定，第二是正确分离视频人物的刚体运动和非刚体运动（即头部位置变化和面部表情变化），第三是克服表情捕捉时复杂光照带来的影响。

构建高质量的面部绑定是完成高保真面部表情捕捉的基础，它不仅能够让算法更为精准地还原各类细节表情，还能在一定程度上防止表情优化过程陷入局部最优。当前，面部绑定方法大致可归为两类。

第一类是基于三维混合形状（blendshape^[4]）的方法。此方法借助预定义的表情基，如中性表情、微笑表情、皱眉表情等，通过线性插值来生成动画。然而，

受限于线性插值的特性，在处理张嘴、闭眼这类涉及绕轴旋转的表情时，容易出现走样和表情瑕疵，缺乏自然形变所具备的非线性细节。

另一类则是基于骨骼绑定的方法。在该方法中，模型顶点通过蒙皮与骨骼建立关联，骨骼的运动通过蒙皮对顶点位置产生影响。由于骨骼的旋转和平移能够模拟真实的肌肉和皮肤运动，因此可以生成更加自然的形变。若能提供足够精细的绑定，这种方法有能力逼真地还原人脸动画的每一处细节。基于此类方法，目前工业界涌现出了以 **MetaHuman** 为代表的高质量人脸骨骼绑定。**MetaHuman** 包含上百套超精细的多层级骨骼绑定，并且通过算法将其推广应用到了任意人物。不过，对于模板角色之外的人物，它仅采用预定义的表情规则，缺乏个性化的表情特征，无法完整还原该人物的所有表情。此外，该框架集成已建模好的表情基存在两个关键限制：其一，其带层级的骨架设计使得反解表情对应的关节变换存在严重的二义性；其二，现有的求解算法在处理如此大量的关节时，求解速度会呈指数级下降。

针对上述问题，本文的第一项工作是基于 **MetaHuman** 绑定，提出了一种能够快速优化表情基对应的多层级骨骼绑定的方法。该方法运用细节等级的原理，首先依据粗粒度的几何信息优化出决定大致外貌的里层关节，随后逐步依据更细粒度的几何信息优化更外层关节，直至完成表面关节的优化，从而获得了满足该多层级骨骼设计的无二义性解。经过对 42 个采集角色的实验，每个表情状态相较于输入表情的几何中值误差仅为 0.43mm，并且支持平滑、合理且无瑕疵的插值。此外，本文通过引入基于信赖域设计的 **dogleg**^[12] 最小二乘优化算法，并借助 GPU 并行计算，将单个表情的优化速度从通用算法的五分钟大幅缩短至十秒以内，进一步提高了算法的实用性。

基于上述高质量的面部绑定，面部表情捕捉成为研究的下一步关键任务。在对精度要求不高的场景中，通常会直接采用稀疏人脸特征点来驱动人物的面部绑定^[3,45,46,47]或者借助神经网络直接预测视频帧图片的表情系数^[50]。但若是要实现对每一个细节神态的精准还原，就需要运用基于合成-分析(**analysis-by-synthesis**^[6])的可微渲染技术，这种可微渲染技术是通过可微渲染生成面部图像，再将其与参考图像进行像素级的细致比较，利用梯度下降等优化算法持续调整表情参数，从而使渲染结果逐渐接近真实表情。不过，在这个过程中，刚体运动（也就是头部位置的变化）和非刚体运动（面部表情的变化）的分离，成为了亟待解决的首要难题。

当人物做出表情时，头部运动往往会导致刚体变换与面部表情变化相互混合。如果将刚体变换和非刚体变换同时纳入可微渲染的求解过程，由于自由度太高，求解过程很难收敛。因此，一种常见的策略是，先利用预测的人脸特征点来计算刚体运动的参数^[2,3]，之后再通过可微渲染求解非刚体运动。然而，在极端表情的情况下，特征点检测的准确率会降低，使得特征点出现较大误差，进而导致刚体运动难以准确求解。针对这一问题，研究人员进行了诸多探索，提出了两类方案以获取更精确的刚体运动参数。其中一类是加设深度摄像头^[17,18]，但消费级深度相机的精度通常在 2mm 左右，利用其捕捉的人脸会包含大量噪声，导致计算刚体变换的准确度较低。另一类方案是使用多目立体视觉^[1,13-16]，该方法能够通过视差原理获得更准确的深度信息。然而，由于人脸各区域的图案高度相似，在视差中进行像素匹配的难度较大。

基于此，本文采用了两个 RGB 摄像头，使用双目立体视觉进行深度估计。为了实现人脸的双目像素匹配，本文设计了一个人脸双目特征匹配网络。该网络基于采集的二百余个角色的人脸数据制作的深度数据集，在目前效果最佳的特征匹配网络上进行训练。训练完成后的网络可稳定得到人脸四千余对匹配点，进而通过立体视觉得到对应的几何点深度和精确坐标。随后，本文使用梯度下降求解器优化出准确的刚体变换和大致的表情，为可微渲染提供了良好的刚体变换和表情初值。

克服复杂光照对人脸可微渲染带来的影响是三个难点中最难解决的问题。人脸的反射属性极为复杂，其中既包含与光照无关的漫反射材质，也有随光照呈现非线性变化的镜面反射材质，还存在次表面散射等与光照密切相关却难以精确建模的材质。即便运用复杂的现代图形学全套渲染管线来制作数字人，也无法实现与真实人脸的完全一致，而在实际拍摄视频时，环境光照又会出现或强烈变化、或微弱变化的情况，复杂的人脸反射属性乘上复杂的光照条件，使由图像通过可微渲染计算表情存在各种难以建模的变量，导致合成结果难以与参考图片精准对齐，优化过程也极易陷入局部最优。

当前，基于可微渲染的方法存在多种局限性。部分方法因使用单目设备，只能借助先验知识或近似处理手段来应对，无法彻底分离光照，致使表情优化难以达到最佳效果^[2,52]，另一些使用多目设备的方法，虽然在一定程度上解决了部分问题，但切换环境光照的成本高昂，每次更换光照都需要重新训练光照适应网络^[1]，还有部分多目设备配置要求较高，仅能在采集室内使用，由于成本较高，其应用

范围也受到了极大限制^[13]。此外，近年来基于 **Gaussian Splatting** 的表达方法在高质量人脸动画生成方面取得了显著进展，该方法能够利用点云数据进行高效的渲染和重建，生成高度逼真的结果。然而，这类方法在支持后期编辑和重新打光方面存在明显不足，这严重限制了其在工业界图形学制作流程中的应用。

为应对复杂光照和材质分离的挑战，本文提出了一种轻量级的解决方案。该方案仅使用两个 **RGB** 摄像头，充分利用漫反射各向同性的特性来分离漫反射材质，并通过参数化贴图对光照信息和材质信息进行建模。通过三个阶段的可微渲染，分别对光照贴图、漫反射贴图和表情系数进行优化，成功实现了光照和漫反射的有效剥离，进而优化出每一帧的精细表情系数和漫反射贴图。此方法支持自由切换各种自然光照，生成的动画与原视频每帧的 **PSNR** 接近 **38dB**。与基于 **Gaussian Splatting** 的方法相比，本文方案依托传统图形学渲染管线，不仅支持动画后期编辑与重光照，而且更契合工业级制作流程的需求，具备更为广泛的应用前景。

1.2 本文工作



图 1.2 本文表情还原、重光照及切换视角效果

本文算法的输入是一段双目视频，以及该人的中性表情三维模型，输出是精准还原视频每帧动画的刚体变换参数、表情系数和外观贴图，支持强烈变化的光

照条件和极端的面部表情，拥有良好的时域稳定性，它由两个步骤构成：构建高质量绑定和高保真面部捕捉，算法效果如图 1.2 所示。

本文首先研究了如何构建视频里人物的高质量绑定。本文通过已有的多视点立体视觉得到三维模型后，将 MetaHuman 模板绑定进行了迁移，之后，结合细节等级的概念，分层级地计算出了张嘴、闭眼表情时的多层级骨骼的无二义性的正确关节位置，使得这套绑定可以更好的贴合该人物的表情特征，为后续的高保真面部表情捕捉打下了坚实基础。

本文的高保真面部捕捉算法基于双目立体视觉及可微渲染来进行。为了解决分离刚体变换和非刚体变换的问题，本文使用双目视觉的视差来估计深度，对得到的大量正确的几何点同时计算刚体变换和非刚体变换参数。为了缓解复杂光照条件的问题及二维图像到三维模型的域差异，本文在利用双目视觉得到的几何点优化完非刚体变换的初值后，使用本文新定义的参数化的贴图，设计了一种多阶段的由粗到细的优化架构，用可微渲染同时优化建模好的光照变化和表情系数，并利用漫反射材质各向同性的属性，优化出支持更换光照的漫反射贴图，该多阶段的优化架构有效避免了优化过程陷入局部最优。实践过程中，在面对人脸这个图案相似、难以在双目视觉中找到对应点的场景，本文使用了 LoFTR^[9]这个目前效果领先的稠密特征匹配神经网络来解决，并修改了部分网络结构以完成亚像素级别的人脸匹配点寻找，并在自主构建的人脸数据集上进行了网络的微调，使其满足项目需要。为了进一步验证方法的有效性，本文进行了定性和定量对比实验，实验结果表明，在基于多边形表达的领域，本文方法在精度和质量上相较现有最先进算法有显著提升。

总的来说，本文的主要贡献可以概括为：

1. 设计了一个可以从双目视频中还原高保真人脸动画的算法，其使用精心设计的多阶段的由粗到细的优化架构，缓解了二维图像到三维模型的域差异，在日常各种复杂光照条件变化下，都可以精准迁移各种精细的面部表情。
2. 提出了一种将一组采集重建的表情转化成面部骨骼绑定的方法，结合 MetaHuman 符合人体运动学的精妙设计，可以使得生成的绑定贴合采集的表情基，并实现平滑、合理、无瑕疵的插值。
3. 利用采集的大量面部数据构建了一个人脸深度数据集，用于训练一个对人脸稠密像素进行双目匹配的神经网络，其可以在不带显式标记点的人脸上得到数千个正确的几何点。

1.3 篇章结构

本文的章节安排如下：

第一章简要阐述了本文的研究背景及存在的挑战，并描述了本文的主要工作。

第二章对本课题的研究现状以及已有的相关工作进行了简要的回顾与分析。

第三章详细介绍了如何从采集的一组表情基构建高质量的面部绑定，包括如何无二义性地计算出 **MetaHuman** 多层级人脸骨骼的关节位置。

第四章详细介绍了本文的高保真面部表情捕捉方法，包括双目匹配得到刚体变换参数和表情系数初值，多阶段、由粗到细的可微渲染优化架构得到最终表情系数和贴图，以及面部深度数据集的构建和人脸双目匹配网络的训练。

第五章介绍了实验的配置环境，给出了实验的结果及对比分析，并通过多项消融实验证明了各个设计的重要意义。

第六章对全文进行总结，并分析了本文方法的一些不足，对未来提出了展望。

第2章 相关工作

关于人脸动画的研究在计算机图形学、计算机视觉和机器学习领域已有悠久的历史^[10,11], 本章将聚焦与之最相关的技术, 并分成四部分进行详细介绍。其中, 人脸建模部分介绍了多视点立体视觉以及参数化人脸建模的流程, 人脸反射属性研究部分介绍了基于物理的渲染下人脸的材质属性和使用可微渲染进行求解的一些方法, 人脸动画驱动方式部分介绍了工业界常用的人脸绑定方法以及隐式表达方法, 面部表情捕捉部分分为单目 RGB、RGBD 和多视点三种配置分别跟踪了目前学术界的最新进展。

2.1 人脸建模

传统图形学渲染物体需要有物体的三维模型和外观属性, 而三维模型的获取有手工建模和采集重建两种, 本文用到的高保真人脸模型, 通常采用采集重建的方式获得, 其主要使用多视点立体视觉技术, 得到人脸的由大量多边形组成的高细节模型(简称高模), 再结合参数化模型生成较少数量多边形构成的低模, 以供表情动画使用。

高精度的采集重建通常将多个摄像机围绕在被采集对象周围, 由拍摄的多视角 RGB 图像通过视差原理进行物体距离计算, 大型电影的制作采用了一种高配置的 LightStage^[48] (如图 2.1a), 其建造成本高昂, 难以获得, 2011 年 Beeler 等人设计了一套由多个 RGB 相机与偏振光源组成的设备^[19] (如图 2.1b), 他们使用该



图 2.1 重建系统示意图

设备重建出了毛孔级别细节的人脸几何模型(如图 2.1c), 其与 LightStage 采用同样的多视点立体视觉技术, 该设备在光源前面加上同样方向的偏振片, 再在相机

前面加上与之方向垂直的偏振片,使得镜面反射的光被偏振片阻挡,只剩下采集对象的漫反射的光,这样相机就可以记录采集对象的漫反射图片,以利用漫反射的视角无关的特性(即各向同性),来找到多目相机成像之间像素对应关系,利用立体视觉计算出人脸上每个像素对应的深度信息。

$$\frac{T}{Z} = \frac{T - (p^l - p^r)}{Z - f} \quad (2.1)$$

$$Z = \frac{fT}{p^l - p^r} \quad (2.2)$$

公式 2.1 和公式 2.2 为立体视觉算法的基础, T 表示两台相机的相对位移, p^l 、 p^r 分别表示同一个点在左右两台相机中的投影点, f 表示相机焦距, Z 表示点在世界坐标的深度, 上述公式当且仅当两台相机成像平面共面时成立, 且因为相机参数已经通过校准获得, 所以仅有 p^l 、 p^r 是未知量, $p^l - p^r$ 称为左到右的视差 (disparity), 根据公式 2.1 和公式 2.2 就可以算出每个像素的深度, 完成几何重建, 在实践中主要分为三个步骤, 第一步是相机矫正, 即把原本不共面的左右相机成像平面对齐; 第二步是进行左右相机特征点匹配, 获得视差图 (disparity map), 以此求解深度信息; 第三步是进行几何后处理。第一步通过张正友标定法^[23]来解决, 通过拍摄已知尺寸的棋盘格图案, 利用特征点的几何关系, 计算摄像机的内参和外参。第二步特征匹配流程中 **Beeler** 等人的做法是采用图像金字塔思路, 从低分辨率图像进行特征匹配获得低分辨率的视差图, 再逐级提高分辨率, 在上一层视差图基础上进一步优化视差, 最终得到高分辨率的视差图, 经过匹配、再匹配与视差优化三个步骤, 步骤之间有筛选步骤, 将误匹配点删除, 最终就可以获得人脸高模。第三步在特征匹配基础上进行几何后处理, **Beeler** 等人通过不断迭代优化 **NCC** (normalized cross-correlation, 归一化交叉相关) 特征最匹配的点的坐标, 来进行几何平面优化以增加细节, 最后再通过从图像的明暗来推测顶点的深度, 进行微观细节的增强, 获得含有丰富细节的高模。

然而高模由于含有数百万个多边形, 模型的分辨率过高, 且不同模型的布线 (也称拓扑) 不一致, 难以用于实时渲染以及人脸动画, 因此人们会用参数化模型拟合获得拓扑一致的低模。3DMM (3D Morphable Model, 三维可形变模型)^[24]将人脸表示为参数化的模型, 通过主成分分析将大量采集的人脸模型压缩成了几

个独立的维度，比如身份信息维度和表情信息维度，通过几组独立的基进行人脸表达，常见的一些 3DMM 有 Basel 人脸模型^[24]以及 Flame 人头模型^[25]等，其中 Flame 人头模型表示是 $V(\theta, \beta, \phi, i)$ ，表示 Flame 在位姿系数 θ ，形状系数 β 和表情系数 ϕ 下人脸模型的第 i 个顶点，位姿系数 θ 代表模型的全局刚体变化， β 和 ϕ 分别表示中性形状和表情系数。在贴合的过程中，首先会由人工标记一些人脸关节点 l_i （比如鼻尖、嘴角等），再利用特征点检测工具对拍摄的图片进行人脸特征点检测，得到二维人脸特征点，然后利用相机参数将高模投影到图像空间，通过公式 2.3 计算出位姿系数，将高模与低模位置对齐，接下来再使用公式 2.4 求解 θ 、 β 与 ϕ 得到低模， λ_θ 、 λ_β 、 λ_ϕ 分别表示 θ 、 β 与 ϕ 正则项的权重，以防止过拟合现象的出现，最后将高模上的其他高频细节烘焙到法线贴图，就得到了该人的一个表情的低模，通过拍摄该人的多个表情，并执行上述流程，即可获得一组该人的拓扑一致的表情基。

$$\min_{\theta_r} \sum_{i=1}^N \|V(\theta, \beta, \phi, i) - l_i\| \quad (2.3)$$

$$\min_{\theta, \beta, \phi} \sum_{i=1}^N \|V(\theta, \beta, \phi, i) - l_i\| + \lambda_\theta \|\theta\| + \lambda_\phi \|\phi\| + \lambda_\beta \|\beta\| \quad (2.4)$$

2.2 人脸反射属性

现代图形学的渲染若追求高保真通常会使用基于物理的渲染（Physically based rendering, PBR）^[34]，其建立在微表面模型的概念上，认为物体达到微观尺度后任何平面都可以用被称为微平面(Microfacets)的细小镜面来进行描绘，根据平面粗糙程度的不同，这些细小镜面可以分为粗糙表面及光滑表面，如图 2.2 所示，



图 2.2 微表面模型

当平行光线照在粗糙表面时，入射光线会向四面八方发散开来，呈现出分布范围

广泛的反射效果，称为漫反射，当平行光线照在光滑表面时，光线大体上会更趋向于向同一个方向反射，造成更小更锐利的反射，称为镜面反射，基于微表面模型的近似法实现了能量守恒，即出射光线的能量永远不会超过入射光线的能量。

$$L_o(p, w_o) = \int_{\Omega} f_r(p, w_i, w_o) L_i(p, w_i) n \cdot w_i dw_i \quad (2.5)$$

对一个场景的渲染可以表示为求解公式 2.5 所示的渲染方程^[34]，它表示对一个几何点 p ，光线沿 w_i 方向射向该点，出射方向是 w_o ，对该点在球面上能接受到的各个方向的光 w_i 积分，得到的 L_o 就是该点 p 沿 w_o 方向反射出的所有的光，公式中的 n 表示几何点 p 的法线方向， $n \cdot w_i$ 即是光线 w_i 在点 p 法线方向上的分量，只有这部分光会被反射， f_r 是双向反射分布函数 (Bidirectional Reflective Distribution Function, BRDF)，它描述了物体表面将光能从入射方向 w_i 反射到另一个出射方向 w_o 的反射特性，基于物理的渲染常使用 Cook-Torrance BRDF 模型^[56]，它的表达式如公式 2.6 所示，包含上面所述的漫反射和镜面反射两个部分， k_d 是被折射部分的能量所占的比率， k_s 是被反射部分所占的比率，公式 2.6 左侧的部分表示漫反射，用 f_{lambert} 表示，它被称为 Lambertian 漫反射，用公式 2.7 表示， c 表示表面颜色，在复杂场景中也可用一张贴图来存储，被称为漫反射贴图 (diffuse 贴图)，

$$f_r = k_d f_{\text{lambert}} + k_s f_{\text{cook-torrance}} \quad (2.6)$$

$$f_{\text{lambert}} = \frac{c}{\pi} \quad (2.7)$$

$$f_{\text{cook-torrance}} = \frac{DFG}{4(w_o \cdot n)(w_i \cdot n)} \quad (2.8)$$

公式 2.6 的右侧部分表示镜面反射，用 $f_{\text{cook-torrance}}$ 表示，见公式 2.8，其分母的 n 表示宏观表面的法线， w_i 表示光线入射方向， w_o 表示光线出射方向，它的分子部分包含三个函数， D 表示法线分布函数， F 表示菲涅尔方程， G 表示几何函数，法线分布函数从统计学上近似地表示了与某些微表面法线取向一致的微平面的比率，粗糙表面法线分布相对均匀，光滑表面法线分布相对集中，工业界中常

用 Trowbridge-Reitz GGX^[57,58]函数来表示法线分布函数, 见公式 2.9, 其中 α 表示表面粗糙度, 也可用一张贴图存储, 称为粗糙度贴图 (roughness 贴图), h 是半程向量 (half vector), 是视角向量 (v) 和光线方向向量 (l) 的归一化和, 代表视角和光线方向的中间方向。几何函数从统计学上近似的求得了微平面间相互遮蔽的比率, 常用 GGX 与 Schlick-Beckmann^[59,60]近似的结合体, 公式为 2.10, 其中 k 是表面粗糙度 α 的一种重映射, v 是视角方向向量 (view vector), 为单位向量, 表示观察者视线方向。菲涅尔方程描述的是被反射的光线对比光线被折射的部分所占的比率, 这个比率会随着观察的角度不同而不同, 可以用 Fresnel-Schlick 近似法求得近似解, 见公式 2.11, 其中 F_0 是基础反射率, 可用一张贴图存储, 也称镜面反射率贴图。

$$NDF_{GGXTR}(n, h, \alpha) = \frac{\alpha^2}{\pi((n \cdot h)^2(\alpha^2 - 1) + 1)^2} \quad (2.9)$$

$$G_{SchlickGGX}(n, v, k) = \frac{n \cdot v}{(n \cdot v)(1 - k) + k} \quad (2.10)$$

$$F_{Schlick}(h, v, F_0) = F_0 + (1 - F_0)(1 - (h \cdot v))^5 \quad (2.11)$$

对于人脸的渲染来说, Donner 等人^[31]于 2006 年提出的一种二层皮肤模型广泛地应用在最近的人脸皮肤建模工作^[32,33]中, 见图 2.3, 二层皮肤模型将人脸材质




图 2.3 二层皮肤介质模型^[31]

建模为漫反射材质和镜面反射材质的线性组合, 根据二层皮肤介质模型, 皮肤光照的镜面反射主要发生在其表面油脂层, 光线在这一层不发生散射, 而油脂层下面的表皮层和真皮层则贡献了皮肤光照中主要的次表面散射部分, 2024 年郝^[62]等

人分析了基于扩散近似的渲染方法和基于蒙特卡洛采样的真实感人脸渲染方法，将人脸恢复工作分类为基于专业采集设备的高精度恢复和基于深度学习的低精度恢复，通过近似，尽管人脸皮肤的外观有着半透明材质的特性，使用双向表面散射分布函数（Bidirectional Surface Scattering Reflectance Distribution Function, BSSRDF）模拟是一个更好的选择，但若兼顾质量和成本，可不考虑次表面散射，使用 Lambert 漫反射和 Cook-Torrance 镜面反射即可获得良好的结果。Lambert 漫反射可使用一张漫反射贴图来记录表面颜色，这一部分与观察角度无关，有各向同性的性质，于是可以从渲染方程 2.5 的积分中提取出来，此时人脸的渲染方程变为公式 2.12，而镜面反射部分可使用 Cook-Torrance 模型，这一部分会随观察角度变化而变化。

$$L_o(p, w_o) = \frac{c}{\pi} \int_{\Omega} f_{\text{cook-torrance}}(p, w_i, w_o) L_i(p, w_i) n \cdot w_i dw_i \quad (2.12)$$

为求解这些反射属性，一个常用的做法是使用可微渲染，即把计算机正向渲染的过程可微化，然后计算渲染图片与参考图片的损失，通过梯度回传优化待求解的变量。传统计算机图形学正向渲染的方法大致可分为两种，一种是光栅化，它是将几何体的边离散地分布在各个像素上，然后再计算各个像素的颜色，该方法有离散的过程，整体不连续，不可微（这里先不考虑通过一些技巧使其可微），还有一种是光线追踪，它其中包含一种可微的渲染流程，即 Kajiya^[34]于 1986 年提出的路径追踪（Path Tracing），它根据光路可逆性原理，模拟光线从相机发射，在与场景中的物体作用，最后与光源相交的过程，具体来说，它使用蒙特卡洛积分，将渲染方程中的连续积分变成随机采样的求和形式，通过让屏幕上的每个像素向四面八方发出 spp（Samples Per Pixel，每像素采样数）条光线，计算这些光线与环境中的物体发生多次弹射，每次弹射的过程中会使该条光线向沿接触面法线对称的方向反射，一部分光被物体吸收，一部分光可以反射，吸收和反射的比例通过 BRDF 来表示，直到光线与光源相交或弹射次数达到限定值，整个过程可微，若使 BRDF 中漫反射或镜面反射相关贴图的参数为变量，即可追踪光线吸收比例对最终效果的影响，其数值是连续的，若使几何形状为变量，即可追踪法线的变化对最终渲染的影响，其影响也是可微的，这就是一种经典的合成-分析（analysis-by-synthesis）求解方法，目前，Wenzel 等人已给出方便的 mitsuba2^[49]

库来模拟这个基于路径追踪的可微渲染过程，其已被学术界广泛应用。基于可微渲染，再结合 IBL 光照^[35]，就可求解出漫反射材质^[36]，再结合 Karis^[34]提出的拆分求和近似处理，就可求解出镜面反射材质。

2.3 人脸动画绑定方法

在得到了人脸的静态三维模型和外观属性后，如何实现高质量的动画，并尽可能减小驱动过程的开支，工业界和学术界已进行了长达三十余年的探索^[63]。基于显式三维模型的方法，可以分为三维混合形状 (blendshape) 和骨骼绑定两种，目前都被工业界广泛应用，最近学术界还出现了基于 Nerf 或 3D Gaussian Splatting 的方法，目前的商业化应用仍处在探索阶段。

2.3.1 三维混合形状方法

三维混合形状 (Blendshape) 技术是一种广泛应用于面部动画的线性建模方法，它通过一组称为目标形状的基表情构建面部动画，这些目标形状是模型的核心，每个形状对应特定的面部表情特征，它们相互正交，如图 2.4(a)所示，图示中通过 w_1 、 w_2 和 w_3 控制的三个表情相互正交，通过线性组合来表示各种各样的表情，其权重控制着各个目标形状对最终表情的贡献，从而实现精确、自然的面部表情变化。从数学角度看，blendshape 模型可以被表示为一个线性代数问题，面部模型的形状可以看作是中性表情和一组目标形状的加权组合，其基本公式为 $f = Bw$ ，其中 f 是面部最终形状， B 是目标形状矩阵， w 是权重向量，通过调整权重值，blendshape 可以生成范围广泛的面部表情，如图 2.4(b)所示，最终表情通过 w_1 、 w_2 权重混合张嘴和咧嘴两个表情基获得。




图 2.4 Blendshape 表情基插值

Blendshape 技术在实现面部动画时具有显著的灵活性。它允许通过直接操控混合表情权重生成动画，或者结合面部捕捉技术实时驱动模型，例如 Cao 等人^[3]就使用回归的方法通过跟踪面部特征点的位置实时计算混合表情权重，Weise 等人^[37]使用 RGBD 相机重建并驱动特定人物的 blendshape 表情基并重定向到漫画人物上，Zielonka 等人^[2]通过 RGB 相机同时完成了重建 Flame 规则的 blendshape 表情基及可微渲染的面部驱动。

虽然 blendshape 被广泛应用于人脸动画，但它其实难以准确模拟基于骨骼的变形^[38]，因为 blendshape 这种形状插值依赖于对预定义关键形状的线性混合，这种方式容易导致过渡时的视觉不真实，例如，在从微笑到中性表情再到皱眉的插值过程中，模型顶点的运动路径在形状空间中呈现直线，这种分段线性插值会产生机械感，缺乏自然形变的非线性细节，使过渡显得僵硬、不流畅，且随着 blendshape 基数量的增加，权重的组合变得愈发复杂且难以操作，各个基也会变得难以相互之间正交，这可能导致复杂表情的控制变得困难，并引发意外的缩放或变形等瑕疵。

2.3.2 骨骼绑定方法

基于骨骼绑定的动画技术被各种动画公司广泛用于制作高保真的面部动画，如 Epic Games 开发的 MetaHuman（见图 2.5）被应用于，原理是通过预定义的骨骼姿态，在这些姿态之间插值，由骨骼的运动驱动模型顶点的变化，从而实现逼真的表情变形。RBF（Radial Basis Function，径向基函数）是一种基于距离的插值方法，特别适合处理稀疏、高维的散点数据，常用于骨骼动画中，RBF 的核心思想是定义






图 2.5 MetaHuman 的数字人生成结果展示

一个连续函数，以若干已知的控制点为基础（在骨骼动画中，这些点通常对应关节的特定姿态，如旋转角度或几何参数），通过这些点计算插值，其关键特性在于，RBF 的插值权重与控制点之间的距离相关，而这个距离通常是欧几里得距离，典型形式包括高斯函数、多项式函数等，能够平滑地插值已知控制点之间的值。在 MetaHuman 骨骼动画中，RBF 的输出是顶点的位移，用来表达关节变形的具体效果。例如，当一个关节旋转至某一特定姿态时，RBF 会基于其距离最近的控制点及其权重，计算出顶点的位移，从而实现自然的形变。这种方法能够高效处理复杂的非线性形变模拟，特别是在关节区域的精细处理上表现出色。与传统的线性插值方法相比，RBF 插值不仅更贴合实际需求，还能大幅提高动画的视觉真实感。通过 RBF，骨骼姿态的变化带动顶点的自然非线性变形，从而实现流畅且细腻的动物表现。

Epic Games 基于此开发了 MetaHuman 动画绑定系统，它预置约 60 套事先制作好的人物绑定，每套绑定均可完成高保真的面部动画，它的顶层实现提供了一组滑块，非专业用户可以轻松利用这些滑块控制面部，大约 200 个控制滑块被映射到约 800 个关节的平移和旋转操作，每个控制滑块都对应了一个骨骼姿态，其官方有给出 Mesh2Metahuman 工具用来将任意拓扑的模型生成该人粗略的 MetaHuman 人物绑定，并发布了 MetaHuman Animator^[64]进行面部动画的捕捉。图 2.6(a)为 MetaHuman 的人脸骨骼绑定，图 2.6(b)为控制人物的滑块控制面板。



(a) MetaHuman 人脸绑定



(b) MetaHuman 滑块控制面板

图 2.6 MetaHuman 人脸绑定及其 UI 控制器

通过带表情的三维模型反解出骨骼绑定的关节变换, 并保证整个动画过程中平滑、合理且没有瑕疵是一个比较难的问题, 虽然 Mesh2MetaHuman 可方便地用中性表情生成初始绑定, 但仍需要解决表情定制化的问题。关于用表情基反解骨骼绑定的关节变换的问题, 科学家们也进行过大量的探索。Rackovic 等人^[53]曾探索了如何通过分区域优化的方式由表情基逆推骨骼绑定(图 2.7), 其将 blendshape 相对于原模型的偏移矩阵在模型和控制器空间中划区并分割, 将整个面部模型划分了若干子模型, 其对于每个局部区域, 用最小二乘法求解逆绑定问题。对于更快速的求解逆绑定问题, Binh 等人提出的 SSDR^[39] (Smooth Skinning Decomposition with Rigid Bones, 线性蒙皮分解) 通过迭代优化的思路, 每次先固定蒙皮权重而优化骨骼位置, 再固定骨骼位置而优化蒙皮权重, 最小化运动过程中的每一个姿态的几何损失, 直到误差不再下降为止, 该方法被广泛应用于工业界中, 但其不支持多层级骨骼的优化, 每个骨骼必须通过算法指定蒙皮权重, 且蒙皮权重不可为零。还有一些工作探索了如何使用最少的表情基表示更多的表情, Carrigan 等人^[5]将选择迁移表情基的问题建模为一个混合整数线性优化问题, 将




图 2.7 Rackovic 等人的 blendshape 聚类^[53]

每个 blendshape 中具有显著位移的顶点标记为活动顶点, 形成二进制表示, 用以优化重叠, 然后结合位移强度和三角形变形程度来评估 blendshape 的重要性, 优先选择对个性化影响大的 blendshape, 通过表情打包 (Expression Packing), 将多个非重叠的 blendshape 合并到一个表情基中, 大幅度减少表情基的数量, 例如, 用少于 20 个表情可以覆盖原本需要上百个 blendshape 的情形。而吴某某等人于 2024 年首次针对东亚人种提出基于元学习的 MetaHuman 快速适配方法, 通过 5 个中性表情样本即可生成基础绑定, 但极端表情的还原误差仍达 1.5mm, 本文则通过引入多表情采集与分层优化 (见 § 3.2), 将误差降低至 0.43mm, 且支持非中性表情的个性化建模。

2.3.3 隐式表达方法

随着由 Nerf (由三维空间点的颜色和体积密度组成的辐射场) 和 3D Gaussian Splatting (由带颜色的点云组成的场景) 这类新颖的场景表示的出现, 人们也探索了使用它们来表达人脸并进行驱动, Lombardi 等人^[14]提出使用多个体素基元 (volumetric primitives) 表示人脸, 场景的运动由基元的几何变换参数 (位置、旋转、缩放) 驱动, Ma 等人^[40]提出使用 3D Gaussian Splatting 表示人脸并使用预训练的表情捕捉网络驱动, 然而目前这些表达还未被工业界广泛应用, 且存在难以更换光照、难以由美术编辑等痛点, 应用场景暂时受限。

2.4 面部表情捕捉

面部表情捕捉即捕捉视频里人物的表情动画, 根据配置复杂程度, 可以分为使用一个普通 RGB 摄像头、使用一个带有深度的 RGBD 摄像头, 以及多个视角。

2.4.1 基于单目摄像头的方法

使用普通单目摄像头进行人脸捕捉因其采集设备简单, 便于用来开发手机 AR 应用等而受到广泛关注, 早期的方法会直接使用稀疏人脸特征点直接驱动面部变形^[3,45,46,47], 此时人脸动画的质量随着人脸特征点检测工具准确度的提升和特征点检测密度的增加而提升, 如 2011 年 Cao 等人^[3]通过跟踪面部特征点的位置实时计算混合表情权重, 在各种数据集上表现出了较高的鲁棒性, 能够在复杂的面部表情和各种光照条件下准确恢复面部的 3D 形状, 在精度方面达到了一个较高水平 (图 2.8a), 随后人们探索了使用 CNN (Convolutional Neural Networks, 卷积神经网络) 来直接回归表情系数, 如 2017 年 Kim 等人^[50]使用了一个巨大的合成数据集来训练了一个 CNN 回归器, 但它们的结果相比于可微渲染的方法来说精




图 2.8 早期单目面部表情捕捉方法

度较差,难以高质量还原精细面部表情,同年 Tewari 等人^[51]使用可微渲染方法,训练一个图像编码器,该编码器通过自监督学习生成表情、漫反射贴图(图 2.8b),2022 年 Zielonka 等人^[2]开始大幅提高表情的真实感和渲染质量,引入度量级重建 (metrical reconstruction) 来提高面部几何重建的精度,这样能够准确地重建面部的度量尺度,避免了形状恢复中的比例失真,随后其使用了可微渲染结合漫反射等贴图,并使用球谐光照进行光照建模,优化之前重建得到的 Flame 三维可变形空间的表情系数以及刚体变换,设置了图像 RGB 的损失和特征点损失以及正则项来多重约束,以求一比一还原视频中人物的表情,但 Flame 表示空间有限,对于极其夸张的面部表情难以表示,恢复的精度可能会有所下降,2023 年 Bharadwaj 等人^[52]用单目视频和 Flame 拓扑做输入,输出一个绑定和 PBR 外观属性(图 2.9a),但单目配置约束不够,难以确定物体其他视角和材质属性,只能靠大量数据集总结的先验及猜测来克服不适定 (ill-posed) 的问题,还原程度有限,针对这类约束不足问题,本文选择使用的双目配置给定了充分约束。2024 年 Ma 等人^[40]开始结合 3D Gaussian Splatting 把重建出的 3D 高斯表情基通过追踪算法进行驱动(图 2.9b),可获得非常拟真的结果,但该表达难以进行后期的编辑和修复,难以融合工业界图形学制作流程,应用面较窄,本文则选择使用传统多边形表达,得到的资产支持重光照、切换视角,可非常方便地融入现在的工业界流程。




图 2.9 最新单目面部表情捕捉方法

2.4.2 基于 RGBD 摄像头的方法

一些添加约束的工作是将单目 RGB 相机升级为 RGBD 摄像头,其少量地增加了配置的难度,但可获得关键的深度信息,2011 年 Weise 等人^[18]通过消费级 RGBD 摄像头基于 blendshape 通过表情重定向驱动了非真实感头像(图 2.10),同期还有众多同类工作^[54,56]使用 RGBD 摄像头将通用的 blendshape 模型通过适配

图 2.10 Weise 等人驱动非真实感头像^[18]

修正或变形，以更准确地跟踪特定用户，随后 2023 年 MetaHuman Animator 实现了由 iPhone RGBD 摄像头获得的图像信息为主，大致的深度为辅，通过可微渲染等方法优化 MetaHuman 表情系数的方法（图 2.11），但其高度依赖艺术家精密制作的个人定制绑定且面捕效果不稳定，个人实际使用时表情还原真实度有限。




图 2.11 MetaHuman Animator 视频采集设备及处理时界面

2.4.3 基于多视角的方法

通过多个视角以立体视觉为辅助再加上多视角图片判断更复杂的材质属性，可使面部表情捕捉获得更加逼真的结果。2024 年 Zhu^[61]等人提出的轻量化采集方案仅需普通双目摄像头和 10 分钟视频即可生成基本可用的面部绑定，但其线性

Blendshape 表达难以处理极端表情。本文结合其采集框架与 MetaHuman 骨骼系统（见 § 3.1），在同等输入条件下支持更自然的肌肉动力学插值，且兼容工业管线。2021 年 Cao 等人^[1]使用双目摄像头，在结合光流和可微渲染离线解算完同一光照环境下的每一帧表情和贴图后，训练了一个实时面部表情捕捉的追踪器，如图 2.12 从左至右分别为原图、解算的结果、几何的损失以及去光照的结果，其虽




图 2.12 Cao 等人方法的原图、结果、几何损失和去光照的结果对比^[1]

然已有比较好的效果，但其每次切换光照时，都需重新训练面部表情追踪器，本文的方法则不需要对于每个不同的光照都重新训练，大大降低了使用的成本和复杂度，接下来还有很多工作^[14-16]通过手持手机围绕人脸转动进行采集，也获得了较真实的效果，2024 年 Huang 等人^[13]使用了最终级的配置——LightStage 得到了最好的结果，其重光照的效果和重建的精度都有空前的提升（图 2.13），但 LightStage 配置过高，对于实际用户的使用有很大难度，其优化得到体素表达也难以融入现有的工业界编辑流程，拓展性有限，所以本文针对该痛点，用双目摄像头的中等难度的配置，设计了一个更稳定、更易用、支持可编辑、可重光照等更多特性的通用算法。




图 2.13 Huang 等人使用 LightStage 进行的面部表情捕捉结果^[13]

2.5 本文方法论框架

本文提出的高保真人脸动画生成方法基于三级联动的理论框架(如图 2.14 所示),其核心思想是通过分层骨骼优化、双目几何约束和频域可微渲染的协同作用,解决复杂光照下表情迁移的三大挑战:绑定个性化、刚体运动分离和材质-光照解耦。




图 2.14 基于三级联动的理论框架

分层骨骼优化对应本文第三章,高质量的绑定是人脸动画的基石,绑定的质量决定了人脸动画的上限,这一部分我们以 MetaHuman 为基线,该多层级骨骼系统本质是物理驱动的肌肉-皮肤模拟的离散化表达,里层关节 (LOD4-2) 控制大范围肌肉运动 (如颧骨旋转),可通过低分辨率几何优化,误差容忍度高,外层关节 (LOD1-0) 模拟皮肤细节 (如皱纹),需高精度几何约束,基于这一特性,本文创新设计的基于 LOD 的分层优化 (数学表达为公式 2.13, 其中 $V_l = C_l V_{LOD0}$, $mask(l)$ 为当前层级关节集, w_{ij} 为蒙皮权重, T_j 为关节变换, V_{rest} 为中性表情的关节位置),可避免高自由度系统的解空间二义性,同时符合生物力学先验,对每个角色解得贴合其表情特征的高质量绑定。

$$\min_{\{T_j\}} \sum_{l=4}^0 \|V_l - \sum_{j \in mask(l)} w_{ij} T_j V_{rest}\|^2 \quad (2.13)$$

双目初值估计对应本文第四章第三节,通过几何一致性约束(通过 LoFTR 网络获取的匹配点云)和时域稳定性约束(相邻帧表情系数差分约束),得到刚体变换和表情系数的初值 $\mathbf{z}_0$,该阶段由双目视觉提供的绝对几何约束,将可微渲染的自由度从 $\text{SE}(3) \times \mathbb{R}^N$ 降至 $\mathbb{R}^N$ (仅优化表情系数 $\mathbf{z}$),避免陷入局部最优。

频域分解渲染对应本文第四章第四节,频域划分的原理见表 2.1 所示,

表 2.1 频域划分原理

阶段	优化目标	频域特性	数学工具
阶段 1	球谐光照系数	低频(环境光)	球谐基分解
阶段 2	视角相关镜面反射	中频(高光)	低分辨率贴图
阶段 3	表情细节几何	高频(皱纹)	高分辨率贴图

通过频域解耦,将渲染方程(公式 2.12)的非线性优化问题分解为三个良态子问题。

所以本文方法的理论优势在于:

生物力学驱动: 分层优化符合面部肌肉的物理层级(见§3.1)

几何-光度分离: 双目约束几何初值,频域分解处理材质-光照耦合(见§4.4.1)

工业兼容性: 基于多边形网格的表达支持重光照与编辑(见§5.2)

2.6 本章小结

本章对本文工作的前置知识和相关工作进行了系统性的阐述,本章先介绍了人脸采集重建的过程,即获得本文所需的中性表情模型和表情基模型的方法,并同时介绍了人脸动画所涉及的立体视觉的原理,接下来介绍了基于物理的渲染,并分析了人脸的材质表现以及使用可微渲染重建人脸材质,为使用可微渲染求解人脸动画的几何和贴图奠定了理论基础,随后介绍了 blendshape 和骨骼绑定的人脸动画驱动方法,其中对骨骼绑定相关的 RBF 函数作用和表情定制的相关工作展开了详细介绍,最后分单目 RGB、单目 RGBD、多视角三种配置系统性地回顾了面部表情捕捉的相关工作,并分析了这些工作的优势和不足,指明了本文面部表情捕捉算法设计的总体方向。值得注意的是,中文研究如周某某等(2024)已成功将可微渲染技术应用于国产影视制作,验证了其在亚洲人种材质采集中的有效性。本文在其工业实践基础上,进一步解决了复杂光照下的表情-材质解耦问题(见§4.4)。

第3章 逐层级计算的面部骨骼绑定

构建高质量的面部绑定是完成高保真面部表情捕捉的基础，它不仅可以使算法更精准地还原各种细节表情，还可以一定程度地避免优化过程陷入局部最优。MetaHuman 可以完成高保真的面部表情，但其所有角色应用同一套表情规则，难以将建模好的个性化表情写入该框架，一个主要原因是带层级的骨架设计为反解表情对应的关节变换带来了严重的二义性，另一个主要原因是现有的求解算法面对如此大量的关节，求解速度会呈指数级下降。本章首先利用细节等级（LOD）的原理，由粗粒度的几何优化出决定大致外貌的里层关节，一步步由更细粒度的几何优化更外层关节，直到优化到表面关节，求得了满足该多层级骨骼设计的无二义性解，又通过使用 Powell 等人于 1970 年提出的 dogleg^[12]算法，并利用 GPU 并行计算，使得一个表情的优化速度达到了十秒以内。

3.1 算法概述

构建高保真面部骨骼绑定的核心目标是通过多层级骨骼系统精确还原个性化表情特征，同时克服传统方法中存在的关节变换二义性与计算效率低下的问题。本算法基于以下关键设计：

分层优化策略：采用细节等级（LOD）原理，从粗粒度到细粒度逐层优化骨骼参数。首先利用低精度 LOD（如 LOD4）优化决定整体外貌的里层关节，再逐步细化至表层关节（如 LOD0），确保优化过程无二义性且层级间解耦。

初始绑定迁移：以 MetaHuman 模板绑定为初值，通过非刚性迭代最近点配准（N-ICP）将任意拓扑的采集模型转换为 MetaHuman 标准布线模型，并迁移骨骼与蒙皮权重信息，构建初始个性化绑定。

高效优化框架：针对大规模非线性最小二乘问题，引入基于信赖域的 Dogleg 算法，结合 GPU 并行计算加速，显著提升求解速度，单表情优化时间控制在 10 秒以内。

算法整体流程如图 3.1 所示，输入是采集的多表情基几何（中性表情与动态表情）及 MetaHuman 模板绑定，算法首先进行模型拓扑对齐，通过 N-ICP 算法将采集模型包裹为 MetaHuman 标准布线模型，确保模型拓扑和顶点语义与 MetaHuman 一致，接下来进行初始绑定生成，复制模板骨骼位置与蒙皮权重，并通过投影与 MVC 插值法调整骨骼位置至目标模型表面，在主要的逐层级优化部

分, 算法从 LOD4 至 LOD0 逐级优化骨骼变换参数, 每级优化中, 将当前 LOD 几何通过重心坐标换算为目标顶点, 利用逆线性混合蒙皮 (公式 3.1-3.2) 反解骨骼动画矩阵 (公式 3.5), 并通过 Dogleg 算法 (公式 3.8-3.11) 最小化顶点残差 (公式 3.7), 最后结果输出, 将优化后的骨骼姿态与蒙皮权重写入绑定文件, 使其支持表情插值与动画驱动。




图 3.1 面部绑定算法流程图

3.2 基于逐层级优化的人脸表情空间计算

3.2.1 基于 MetaHuman 模板构建初始绑定

本文基于 MetaHuman 完成人脸动画，首先需要由给定的中性表情构建符合 MetaHuman 规则的初始绑定。MetaHuman 的面部绑定采用了多层级骨骼系统，通过分层结构实现精细化控制和高保真的人脸动画表现，它将骨骼划分为了主骨骼、表情骨骼和辅助骨骼三个层次，分别负责整体运动、大表情驱动和细节调整。主骨骼控制面部的全局运动，例如头部旋转和下颌开合；表情骨骼聚焦于眉毛、




图 3.2 MetaHuman 多层级骨骼系统

眼睛、鼻子和嘴唇等区域，支持丰富的表情生成；辅助骨骼则针对肌肉拉伸、皮肤褶皱等微观变化进行细节优化。如图 3.2 表情骨骼层次的下嘴唇部分，每个层次包含一级或多级骨骼，下级骨骼以上级骨骼为坐标系原点进行平移、旋转运算，只有最表层骨骼会对模型有影响，该影响作用被称为线性混合蒙皮，可用公式 3.1 表示，其中 v' 表示变换后的顶点位置， v 表示变换前的顶点位置，顶点通常采用 $[x, y, z, 1]^T$ 齐次坐标形式，以方便平移和旋转的矩阵运算， n 表示影响该顶点的骨骼数量， w_i 表示骨骼 i 对该顶点的蒙皮权重 ($w_i \geq 0$ ，且 $\sum_{i=1}^n w_i = 1$)， T_i 表示骨骼 i 的变换矩阵，包括旋转、缩放和平移等变换，由绑定矩阵 B_i 和动画矩阵 A_i 通过公式 3.2 计算得到，绑定矩阵定义了骨骼和顶点在初始状态下的关系，通常会在中性表情下将骨骼以一定的旋转角度放在世界中某个位置，并将该位置和旋转角度写在绑定矩阵中，动画矩阵则表示动画过程中骨骼变动到的位置和旋转角度，与绑定矩阵的逆相乘后再通过蒙皮权重作用到该关节所影响的所有顶点，就实现了模型的变形，本节将探讨如何得到绑定矩阵 B_i ，以及每个骨骼 i 对每个顶点的蒙皮权重 w_i 。

$$v' = \sum_{i=1}^n w_i T_i v \quad (3.1)$$

$$T_i = A_i B_i^{-1} \quad (3.2)$$




图 3.3 表层关节分布（蓝色圆球为关节）

如图 3.4 所示，初始绑定构建的第一步为模型包裹，该步骤以采集的任意拓扑的表情基和一套 MetaHuman 模板模型为起始，通过模型包裹算法将采集的表情基转换为 MetaHuman 布线表情。该环节使用非刚性迭代最近点配准算法^[41]（Nonrigid Iterative Closest Point, N-ICP）将重建得到的不符合 MetaHuman 模型拓扑（也称模型布线）的低模进行包裹，包裹后模型需满足 MetaHuman 的顶点语义映射（如顶点#2034 始终对应左内眼角），这是后续蒙皮权重迁移的前提。实验中采用 Wrap4D 软件的 N-ICP 实现，设置最大迭代次数为 50，收敛阈值 0.1mm。




图 3.4 模型包裹示意图

关节位置迁移基于最近邻顶点刚性假设（公式 3.3）。如图 3.2 所示，表层的关节都吸附在模型的表面，该表层关节吸附性源于 MetaHuman 的骨骼-皮肤耦合设计，其物理本质是模拟皮肤与皮下组织的生物力学锚定点，所以选取一个与目标人物相似的模板人物，计算出每个关节 J_i 到最近的模型顶点 M_i 的相对位置 Δx_i ，再把每个关节 J_i 放在目标模型中的模型顶点 M'_i 的距离 Δx_i 的位置，同时将模板人物的蒙皮权重复制目标人物上，里层的关节则根据相邻顶点的位置关系使用 MVC^[42] (Mean Value Coordinates) 方法推断，至此已获得该人物初始的 MetaHuman 绑定，拷贝模板人物预置好的骨骼姿态后即可进行与模板人物一致的面部动画。

但每个人物的表情特点千差万别，由他人所有表情组成的表情空间无法覆盖本人的所有表情，由模板绑定的表情基张成的空间可能无法覆盖目标人物的表情流形，即存在表情间隙（如公式 3.4 所示），这需要通过 § 3.2 的逐层级优化填补，求解出人脸动画本人的表情空间。

$$J_i^{\text{new}} = M_i^{\text{target}} + \underbrace{(J_i^{\text{template}} - M_i^{\text{template}})}_{\Delta x_i} \quad (3.3)$$

$$\min_{\{w_k\}} \left\| V^{\text{target}} - \sum_k w_k \phi_k^{\text{template}} \right\| > \epsilon \quad (\epsilon \approx 0.5\text{mm}) \quad (3.4)$$

3.2.2 逐层级计算的关节求解器

在 MetaHuman 初始绑定的基础上，再给定角色若干表情的低模，求解出这些表情对应的骨骼姿态，并保证求得的骨骼姿态符合 MetaHuman 的设计规则，就可以利用其多层级骨骼的设计，实现模型在这些姿态中平滑、合理、无瑕疵的插值，得到表情自然且符合该人特点的表情空间。但用带表情的模型反向模拟出关节的变化，对线性混合蒙皮的过程进行逆向，是个有挑战性的问题，同时对于这个只有表层关节有蒙皮信息的多层级骨骼系统来说，父关节的运动几乎不可能简单通过逆向求解出来，因为表层关节的运动就已经决定了带表情模型的形状 (shape)，父关节的运动只是保证插值过程的合理。如果没有完整求解出链条上所有关节的运动，那求解的结果将没有意义，该人物并不能做出自然、合理的表情动画。

本算法以人脸的物理结构为基础，将运动分解为骨骼、肌肉和皮肤的层级变化，从而设计出基于逐层级优化的优化策略：设第 l 层的几何误差为

$E_l = \|V_l - \sum_j w_{ij} T_j V_{rest}\|^2$, 其中 V_l 通过重心坐标插值从 LOD0 获得, 分层优化即求解 $\min_{T_j \in \text{mask}(l)} \sum_{l=4}^0 E_l$, $\text{mask}(l)$ 为当前层级的关节集合。

根据观察, MetaHuman 的设计结合了细节等级 (Level of Details, LOD) 的




图 3.5 LOD4 的关节分布 (左图) 与 LOD0 的关节分布 (右图)

概念, 如图 3.5 所示, 低精度 LOD (LOD4) 的模型只拥有人物大致的外貌, 拥有少量的关节, 只能做出基础表情, 高精度 LOD (LOD0) 的模型拥有更多的细节、大量的关节, 可以做出非常细腻的表情。如图 3.6 所示 (重点关注每行的虚线框内的区域), 调节控制器到同样的幅度, 低精度 LOD 的模型只能做出大致的样貌, 而更高精度 LOD 的模型则可依次表现出越来越丰富的神态。同时, 更高精度 LOD 新增的关节都是上一精度 LOD 已存在关节的子节点, 且更高级精度 LOD 新增关节的变动都不会改变上一精度 LOD 原有关节的位置, 不同 LOD 拥有不同关节数量:

表 3.1 不同 LOD 层级的关节数量及优化目标

阶段	关节数量	控制区域	优化目标
LOD4	18	下颌骨、颅骨主轮廓	头部整体姿态 (刚体运动近似)
LOD3	42	颧骨、额骨、鼻基底	大范围肌肉群运动 (如咀嚼肌收缩)
LOD2	106	眼轮匝肌、口轮匝肌外围	中等表情 (如微笑、皱眉)
LOD1	254	嘴唇细纹、眉间纹	微表情 (如嘴角抽动)
LOD0	623	皮肤毛孔级细节	极端表情 (如狰狞) 与动态皱纹

因此我结合此观察,设计从低精度 LOD 逐级向高精度 LOD 优化,最终生成细腻的结合结果。对于每个表情,从 LOD4 开始优化每个关节的运动,在此步得到的关节运动基础上再优化 LOD3 新增的关节的运动,直到优化到 LOD0,每个精度的优化过程中使用该精度的几何,这些几何通过从 LOD0 利用重心坐标换算得到,由于每个表情拥有相同的拓扑和顶点语义(顶点语义一致是指两个几何模型之间的顶点具备相同的语义信息,即同一编号的顶点在不同模型上具有相同的几何或解剖意义,例如,若模型A和模型B的顶点语义一致,则在模型A中表示上眼皮四分之一位置的点 M_1 ,其对应点 M_1 在模型B中也位于B的上眼皮四分之一位置,换言之,对于所有顶点 M_i ,它们在模型A和模型B中的几何意义是一致的,均可以对应到同一语义类别的局部解剖或几何特征),所以每个角色每个表情都可以使用同一套重心坐标换算关系,表示为权重矩阵 $C(n \times m$ 矩阵, n 为该 LOD 下的点数,



图 3.6 不同 LOD 的表情细节丰富程度

m 为原始模型的点数),该坐标换算关系可用公式 3.5 表示,对于某个 LOD1 的顶

点 $p_i^{(1)}$, 在 LOD0 的某个三角形面片 $\Delta(v_1, v_2, v_3)$ 上找到其重心坐标表示, w_1, w_2, w_3 为每个顶点对应的重心坐标权重, 可用公式 3.6 求得, 对于 $p_i^{(1)}$, 已知其投影点位于 LOD0 的某个三角形面片 $\Delta(v_1, v_2, v_3)$ 内, $Area(A, B, C)$ 表示由点 A, B, C 构成的三角形的面积。由带表情的几何通过逆线性混合蒙皮求得骨骼姿态的方法, 将在 3.2.2 节中详细介绍, 为使如此大规模的计算快速得到结果, 在 3.2.3 节中介绍了有效的快速求解方法。

$$p_i^{(1)} = w_1 v_1 + w_2 v_2 + w_3 v_3, \quad w_1 + w_2 + w_3 = 1 \quad (3.5)$$

$$w_1 = \frac{Area(p_i^{(1)}, v_2, v_3)}{Area(v_1, v_2, v_3)}, w_2 = \frac{Area(v_1, p_i^{(1)}, v_3)}{Area(v_1, v_2, v_3)}, w_3 = \frac{Area(v_1, v_2, p_i^{(1)})}{Area(v_1, v_2, v_3)} \quad (3.6)$$

关节的运动包含平移、旋转和缩放, 通过蒙皮作用于模型, 3.1 节介绍了绑定矩阵 B_i 的计算方法和线性混合蒙皮的一般原理, 动画矩阵 A_i 实质性地决定了模型的变形, 对于每个表情的骨骼姿态的求解, 其实是求解每个关节的动画矩阵, 对于该多层级的骨骼系统, 每个关节的动画矩阵计算过程会通过公式 3.7 链式计算, 将该关节的局部变换矩阵与其父关节的全局变换矩阵相乘, 得到全局的动画矩阵 A_i , 而关节的全局变换矩阵由父关节的局部变换矩阵与祖父关节的全局变换矩阵相乘, 如此链式求解直到根节点为止, 公式 3.7 的 T_{local} 是每个骨骼自己的局部变换矩阵(相对于父骨骼的位移、旋转和缩放), T_{parent} 是其父骨骼的全局变换矩阵, 变换矩阵采用 $\begin{pmatrix} R & T \\ 0 & 1 \end{pmatrix}$ 的齐次变换矩阵形式, 其中 R 表示旋转矩阵, T 表示平移矩阵,

$$A_i = T_{parent} \cdot T_{local} \quad (3.7)$$

平移矩阵为一个向量 $T = [tx, ty, tz]^T$, 其中 tx, ty, tz 分别表示 x 轴、 y 轴、 z 轴方向上的平移, 旋转矩阵 R 通过四元数 $q = (x, y, z, w)$ 换算得到, 见公式 3.8, 其相比于欧拉角来说插值更平滑从而更容易求解, 且没有欧拉角的两个旋转轴重合时自动失去一个自由度的万向节死锁问题。

$$R = \begin{bmatrix} 1 - 2y^2 - 2z^2 & 2xy - 2zw & 2xz + 2yw \\ 2xy + 2zw & 1 - 2x^2 - 2z^2 & 2yz - 2xw \\ 2xz - 2yw & 2yz + 2xw & 1 - 2x^2 - 2y^2 \end{bmatrix} \quad (3.8)$$

关节求解器使用逐层级计算的逆线性混合蒙皮实现, 从 LOD4 的关节开始一级级向 LOD0 的关节计算, 逆线性混合蒙皮可以通过最小二乘方法求解, 即通过高斯-牛顿^[43]等最小二乘方法求解公式 3.9, 其中每个关节的齐次变换矩阵 T_j 由参数 x, y, z 轴的平移 tx, ty, tz 以及旋转的四元数 rx, ry, rz, rw 通过前述方法运算得到, 逐层级关节优化算法流程图见算法 1, 将每个表情基从 LOD4 开始向 LOD0 优化完成即可得到理想的结果, 每级 LOD 所包含的关节已事先制作为掩码矩阵 $mask$ ($l \times k$ 布尔矩阵, l 为参与优化的 LOD 总级数, k 为关节总数, 值为 True 代表关节包含在该级 LOD 中, 值为 False 代表不包含在该级 LOD 中)

$$\min_{\{T_j\}} \sum_{i=1}^n \left\| v_i' - \sum_{j=1}^k w_{ij} T_j v_i \right\|^2 \quad (3.9)$$

算法 1: 逐层级关节优化

输入:

$\mathcal{V}_{LOD0}$: 表情基模型集合 (p 个模型, 每个模型是 $m \times 3$ 矩阵, m 为模型点数)
 V_{rest} : 中性表情模型 ($m \times 3$ 矩阵)
 J_{init} : 关节的初始位置 ($k \times 3$ 矩阵, k 为关节数量)
 R_{init} : 关节的初始旋转 ($k \times 3 \times 3$ 张量)
 W : 蒙皮权重矩阵 ($m \times k$ 矩阵)
 $mask$: 每级 LOD 对应的关节掩码 ($l \times k$ 的布尔矩阵)
 C : 每级 LOD 模型与 LOD0 模型的坐标权重矩阵集合 (l 级 LOD, 每级 LOD 对应一个 $n \times m$ 矩阵, n 为该级 LOD 的模型点数)

输出:

J_{final} : 优化后的关节位置集合 (对应 p 个模型, 每个是 $k \times 3$ 矩阵)
 $\mathcal{R}_{final}$: 优化后的关节旋转集合 (对应 p 个模型, 每个是 $k \times 3 \times 3$ 张量)

```

1   $max\_iter \leftarrow 100$  // 最大迭代阈值
2   $\epsilon \leftarrow 10^{-6}$  // 收敛阈值
3  for  $t = 1$  to  $p$  do
4       $V_{LOD0} \leftarrow \mathcal{V}_{LOD0}[t]$ 
5      for  $lod = 4$  to  $0$  do
6           $V_{target} \leftarrow C[lod] \cdot V_{LOD0}$  // 计算目标顶点

```

```

7       $J \leftarrow J_{init}$  // 初始关节位置
8       $R \leftarrow R_{init}$  // 初始关节旋转
9       $iter \leftarrow 0$ 
10     while  $iter < max\_iter$  do
11         // 正向计算: Linear Blend Skinning (使用所有骨骼)
12          $V_{pred} \leftarrow LinearBlendSkinning(V_{rest}, J, R, W)$ 
13         // 计算残差: 目标顶点与预测顶点的差异
14          $residual \leftarrow V_{target} - V_{pred}$ 
15         // 构建最小二乘问题: 仅优化掩码为 True 的骨骼
16          $\Delta J, \Delta R \leftarrow SolveLeastSquares(V_{rest}, J, R, W, mask[lod])$ 
17         // 更新关节位置和旋转 (仅更新掩码为 True 的骨骼)
18          $J[mask[lod]] \leftarrow J[mask[lod]] + \Delta J[mask[lod]]$ 
19          $R[mask[lod]] \leftarrow R[mask[lod]] + \Delta R[mask[lod]]$ 
20         // 检查收敛条件
21         if  $\|\Delta J[mask[lod]]\|_2 < \epsilon$  and  $\|\Delta R[mask[lod]]\|_2 < \epsilon$  then
22             break
23         end if
24          $iter \leftarrow iter + 1$ 
25     end while
26      $\mathcal{J}_{final} \leftarrow \mathcal{J}_{final} \cup J$ 
27      $\mathcal{R}_{final} \leftarrow \mathcal{R}_{final} \cup R$ 
28 return  $\mathcal{J}_{final}, \mathcal{R}_{final}$ 

```

但使用高斯-牛顿法进行最小二乘优化的过程中, 优化过程常陷入局部最优, 且后期难以找到正确的梯度下降方向, 耗时较长, 对于如此大规模的非线性最小二乘问题, 还需要探索更鲁棒、更快速的方法。

3.2.3 GPU 加速的 Dogleg 算法

Dogleg^[12]方法是一种基于信赖域 (trust region) 策略的优化方法, 专为大规模非线性最小二乘问题设计。它结合了梯度下降法和高斯-牛顿法的优点, 通过在信

信赖域内选择步长路径, 实现稳定的全局收敛性和较快的局部收敛速度, Dogleg 算法的核心是解决公式 3.10 的优化问题, 其中 $r(x)$ 是残差向量, $J(x)$ 是残差的雅可比矩阵, Δ 是信赖域的半径, 本文将基于 Dogleg 算法完成关节参数的快速求解。

$$\min_{\Delta x} \|r(x) + J(x)\Delta x\|^2, \quad \text{subject to } \|\Delta x\| \leq \Delta \quad (3.10)$$

$$\Delta x_{GD} = -\frac{\|\nabla F\|^2}{\|J\nabla F\|^2} \nabla F \quad (3.11)$$

$$\Delta x_{GN} = -(J^T J)^{-1} J^T r \quad (3.12)$$

$$\Delta x = \Delta x_{GD} + \alpha(\Delta x_{GN} - \Delta x_{GD}) \quad (3.13)$$

逆蒙皮问题是非线性最小二乘问题, 其 Hessian 矩阵 $J^T J$ 在表情幅度大时可能病态。Dogleg 算法通过信赖域约束 (图 3.7) 结合最速下降与高斯-牛顿方向, 相比纯高斯-牛顿法对初始值不敏感, 且 GPU 并行化时迭代次数减少 50% (如表 3.2 所示)。Dogleg 方法通过在梯度下降方向和高斯-牛顿方向之间选择步长路径, 找到满足信赖域约束的最优点。其初始方向为最速下降法的梯度下降方向, 计算公式为公式 3.11, 其中 $\nabla F = J^T r$ 是目标函数的梯度, 如果此时信赖域允许, 则计算高斯-牛顿方向, 公式为 3.12, 若高斯-牛顿方向不满足信赖域约束, 则沿梯度下降方向和高斯-牛顿方向构成的路径选择步长 Δx , 见公式 3.13, 其中 α 是根据信赖域半径确定的比例因子, 接下来每一步迭代计算, 计算新的步长, 更新步长时, 目标函数会被调用并计算新的残差, 通过比较新的残差和上一个残差, 判断是否有改进, 如果改进有效, 则更新输入向量, 如果改进无效, 则调整信赖域的大小, 并重新计算步长, 当步长变得足够小, 或者目标函数没有显著改进时, 停止迭代。

表 3.2 Dogleg 与 LM 算法的优化效率对比

	平均迭代次数	单次迭代时间 (ms)	收敛时平均误差 (mm)	内存占用(MB)
Dogleg (GPU)	38	12.7	0.43	124
LM (CPU)	72	28.3	0.41	89
LM (GPU)	65	18.5	0.45	217

可以用图 3.7 表示这个优化的过程，圆形代表信赖域 Δ ，即在当前迭代中，允许的最大步长范围，步长的选择必须在这个圆形内，以确保数值稳定性和收敛性，点 x 表示当前迭代点的参数向量，即优化问题当前的解， h_{sd} 是梯度下降方向(Steepest Descent)，它是基于当前梯度计算的最速下降方向， h_{GN} 是高斯-牛顿方向(Gauss-Newton)，它是根据目标函数的二阶导数(Jacobian 矩阵)计算的， h_{dl} 是Dogleg步长，它是最终的步长方向，通过结合梯度下降方向和高斯-牛顿方向由公式 3.13 计算得到， a 和 b 即表示 Dogleg 算法的两个候选步长，分别是梯度下降方向和高斯-牛顿方向，最终的步长 h_{dl} 就是这两者根据公式 3.13 做出的权衡。




图 3.7 信赖域与 Dogleg 步长

与高斯-牛顿法相比，Dogleg 算法信赖域的设计对于该关节参数优化任务这个初始点离最终结果较远的场景，可以更好的保证结果的收敛，其通过信赖域半径调节步长，避免了过长或无效的步长，相比于高斯-牛顿法这个更适合局部优化且初始点较为准确的最小二乘优化方法来说，实践表明 Dogleg 更适合此优化 2000 余个参数且初始点偏离较远的逆线性混合蒙皮问题，在 AMD Ryzen 9 5900HX CPU 上逐层级优化 LOD4 至 LOD0 约 2000 个参数，高斯-牛顿法最短需要 5 分钟，且当表情幅度较大时会陷入局部最优，无法收敛，而 Dogleg 算法在 1 分钟内即可稳定完成优化，算法效率大大提高，可在同样的时间内支持更多表情基的解算，更大地丰富表情空间的贴合度。进一步地，在使用 Pytorch 实现 Dogleg 算法的过程中，通过避免显式循环并将目标函数进行包装，其还可以使用 GPU 并行计算的能力进一步实现五至十倍的加速，每个表情的最长优化时间可控制在十秒以内。对于一组由五十个表情基组成的绑定，在十分钟之内即可完成优化，并写入 MetaHuman 绑定的存储文件中。

3.3 结果分析

本节对本章的算法进行效果和效率上的评估。实验使用了 § 2.1 提及的高精度采集重建方法进行人脸表情基的采集，总共采集了 42 名对象，每个对象采集了中性、微笑、张嘴、撅嘴、左撇嘴、右撇嘴、闭眼、抬眉 8 个表情基，之后在一台配备 NVIDIA RTX 3080 GPU 的电脑上进行表情基到骨骼绑定的解算。图 3.8 展示了本章算法生成绑定的插值结果（每个人物展示了 8 个表情中的 1 个）。第一列为中性表情（或起始表情），第二至第五列分别为 20%、40%、60%、80% 比例插值的结果，第六列为该表情全部生效的结果。




图 3.8 本章算法生成绑定的插值结果

从图中可以看出，本章算法生成的绑定，其插值线性、平滑，且整个过程没有瑕疵，其该方法生成的绑定不仅完全可以用于面捕算法解算表情，还可以由动画师或者用户方便地操控表情，例如图 3.9 所示，其可以通过 Maya 中的控制面板，将撇嘴表情从左撇嘴方便地调整为右撇嘴，具有广阔的应用前景。




图 3.9 通过 Maya 使用本章绑定进行表情调整

图 3.10 比较了完成人脸表情空间计算前后的差异，并通过色温图来展示与真实模型的差异，图 3.10a 展示了将包裹后的中性表情使用 MetaHuman 官方的 MetaHuman Creator 中的 Comform 流程（此流程的前提是模型已与 MetaHuman 的




图 3.10 人脸表情空间计算前后的对比

布线一致，使用本流程将不对模型的形状和布线做任何改动，仅进行绑定，以确保对比过程控制变量）绑定后做出向右嘟嘴表情的结果，图 3.10b 展示了将包裹后的中性表情进行 § 3.1 初始绑定构建后做出向右嘟嘴表情的结果，图 3.10c 展示了在图 3.10b 基础上完成人脸表情空间计算后做出向右嘟嘴表情的结果，图 3.10d 为采集的真实的向右嘟嘴表情的模型。从图中可以看出，Creater 的 Comform 流程绑定的结果与本文初始绑定的结果没有明显差异，说明 § 3.1 节的构建初始绑定与 MetaHuman Creater Comform 流程基本一致，为保证算法流程的完整性及自主可控，本文使用 § 3.1 节的构建初始绑定进行后续动作，由图中还可以看出，与真实模型对比来看，未经过人脸表情空间计算的绑定做出向右嘟嘴语义的表情不能还原本人的特征，而经过人脸表情空间计算后的结果与真实结果可以做到对齐。

表 3.3 列出了对所有人物的所有表情进行解算，其表情终值与采集表情差异的平均值和中值。此外，还比较了小于 0.2mm，小于 0.5mm 和小于 1mm 部分的比例。通过这些数据可以看出，表情的终值可以很好地贴合采集的表情，使得本章算法生成的绑定可以很好地还原本人采集的表情，再加上其插值路径平滑、合理、无瑕疵，使得该绑定可以很好地还原本人的特征，且该绑定包含的整个表情空间可以很好地贴合本人所做的几乎所有表情。

表 3.3 优化表情终值与采集表情误差

平均误差(mm)	中值误差(mm)	<0.2mm(%)	<0.5mm(%)	<1mm(%)
0.62	0.43	31.7	68.2	99.4

3.4 本章小结

本章首先介绍了 MetaHuman 多层级骨骼框架，并通过模型包裹将任意拓扑的几何与 MetaHuman 模型布线和顶点语义对齐，以方便通过迁移 MetaHuman 模板角色实现快速绑定。接下来在人脸表情定制上，本章结合细节等级的概念分层级计算出了无二义性的正确关节位置，利用了远处物体可以观察到粗粒度的外貌，近处物体可以观察到细粒度的细节，类似细节等级（LOD）的原理，由粗粒度的几何优化决定大致外貌的里层关节，一步步由更细粒度的几何优化更外层关节，直到优化到表面关节，因为里层关节没有蒙皮信息，蒙皮结果全部由表面关节决

定，且外层关节优化的结果不会影响到里层关节，所以该优化策略可以很好地求得满足人脸骨骼-肌肉-皮肤多层级骨骼设计原则的无二义性解，并且支持 **MetaHuman** 自带的平滑、合理、无瑕疵的表情插值，进一步地，本章通过使用引入信赖域设计的 **dogleg** 算法，并利用 GPU 并行计算，使得一个表情的优化速度达到了 10 秒以内，相比工业界常用的线性蒙皮分解长达 30 分钟的优化时长，提升巨大。后续章节的双目视频驱动人脸动画将在此绑定上进行。

第4章 基于可微渲染及立体视觉的人脸动画

如何在各种复杂的光照条件下，精准迁移各种精细的面部表情，是高保真面部表情捕捉的主要挑战^[1]。复杂的人脸反射属性乘上复杂的光照条件，使由图像通过可微渲染优化三维模型的过程存在各种难以建模的变量，合成结果难以与图片结果对齐，优化过程很容易陷入局部最优，再加上做表情时还会因头部运动而混合刚体变换，都为求解表情带来了不小的挑战。本章用第三章得到的高质量绑定，降低了非刚体变换的求解维度，又在此基础上分三个阶段，由粗到细地进行可微渲染优化，结合球面谐波函数和新设计的参数化光照贴图，成功缓解了二维图片到三维模型的域差异，支持日常的复杂光照条件变化下的面部表情捕捉，并利用漫反射材质各向同性的属性，优化出支持更换光照的漫反射贴图。而对于刚体变换的求解，本章则利用双目的配置，使用人脸双目特征匹配神经网络得到数千个正确的几何点，其中人脸双目特征匹配神经网络利用大量面部数据构建的人脸深度数据集，训练一个稠密像素匹配网络获得。

4.1 硬件及数据准备

本章人脸动画是以第三章解算得到的面部骨骼绑定为人脸表情空间，通过优化 MetaHuman 控制器滑块的值（下文称为表情系数）实现的。面部表情视频采集将采用双目摄像头的配置，采集设备见图 4.1，图 4.1 所示的双目视频采集设备包含了两台佳能 800D 相机，通过三脚架站立在地面上，位于待采集人物左前方和



图 4.1 双目视频采集设备

右前方约 20° 角度处，正前方放置了一个显示器和电脑，通过局域网连接了两台相机，用于控制相机开始和停止录像，而多相机的同步常用的方法是使用支持一键多控的高级相机，或通过电控设备同步发送开始停止信号，考虑到本工作力求降低使用门槛，尽量可以让使用者就地取材，不常见的设备（如相机）也尽量使用最低的配置，本文使用普通的佳能相机，配合手动信号进行相机同步。在录制开始前，使用家里最常见的手电筒在相机视野内完成一次点亮操作，在两个相机的刷新率一样的前提下，将视频从手电筒亮灯瞬间开始向后截取，后面的部分即都是同步的，接下来，使用相机拍摄的视频帧图片恢复三维坐标，或将三维模型渲染至与视频帧对齐，需要完成世界坐标系与像素坐标系之间的转换，此过程需借助相机标定板将相机进行标定得到相机的位置，为方便流程，本文使用 2×2 的标定板，可以使拍摄者在录制表演前，将标定板举至面前完成相机标定，整个过程可以只由拍摄者一人完成。开始前需要将两个相机调至录像模式，并设置关闭录像的实时追踪对焦功能，接下来通过 UI 界面操作两个相机对焦到人脸并锁定对焦，然后点击开始录像，将手电筒举到两个相机能拍摄到的区域内，完成一次点亮熄灭，随后拍摄标定板，在保证棋盘格包含在两个相机取景框的前提下，移动标定板到 16 个不同的位置，如图 4.2，每个位置停留一秒钟左右，接下来取下眼镜，就可以开始正式的表演了，在录制完成后点击结束录制并导出视频，视频采集就完成了。




图 4.2 16 张标定板拍摄图

采集的视频数据包含未同步部分，相机标定部分以及正式视频三个部分。未同步部分通过裁剪手电筒亮起瞬间前的视频帧去除，相机标定部分则需要从连续视频中挑选出 16 张棋盘格清晰、完整的视频帧，通过张正友标定法进行相机标定，其作用是通过棋盘格上的角点利用透视投影关系，建立从世界坐标系到图像坐标系的投影方程，即世界坐标系的三维坐标 (X, Y, Z) 到二维图像坐标 (u, v) 的映射，计算机使用该映射即可模拟出照相机的拍摄过程，该映射由内参矩阵和外参矩阵构成，公式 4.1 描述了将三维坐标从世界坐标系投影到图像坐标系的过程，

$$P^v = \begin{bmatrix} f_x & 0 & c_x \\ 0 & f_y & c_y \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} R & t \\ 0 & 1 \end{bmatrix} M \quad (4.1)$$

f_x 和 f_y 分别表示相机在 x 轴和 y 轴上的焦距， c_x 和 c_y 分别是光心在 x 轴和 y 轴上的坐标，这四个值构成了相机的内参矩阵，描述了相机的内部几何属性。矩阵 R 为相机相对于世界坐标系的旋转矩阵，向量 t 为相机相对于世界坐标系的平移向量，二者共同组成了相机的外参，描述了相机在世界坐标系中的位置和朝向。在相机投影过程中，世界坐标系下的几何点 $M = (X, Y, Z)$ 通过相机的内外参变换后，得到一个三维投影点 $P^v = (X', Y', Z')$ 在相机坐标系中的表示，这个投影点 P^v 是一个齐次坐标表示，即包括了最后一维的 Z' 值。为了得到该几何点在相机下的像素坐标 $M^v = (u, v)$ ，还需要将 P^v 中的三维坐标 (X', Y', Z') 投影到二维图像平面上，这个过程通过将三维坐标的 x 和 y 分别除以 z 值实现，得到归一化后的坐标 $(x', y', 1)$ ，此时前两维即为实际的像素坐标 (u, v) ：

$$u = f_x \cdot \frac{X'}{Z'} + c_x \quad (4.2)$$

$$v = f_y \cdot \frac{Y'}{Z'} + c_y \quad (4.3)$$

在实践中，张正友标定法的实现会使用 `opencv` 库中的 `calibrateCamera` 函数先得到两个相机各自的内参，然后通过函数 `stereoCalibrate` 得到两个相机的外参。由此，就得到了高保真人脸动画所需的所有资产：两个相机的内参和外参，完成同步的两个视角的视频，视频人物的高质量 `MetaHuman` 绑定，以及采集重建的原尺寸模型和漫反射贴图。

4.2 算法概述

本算法结合可微渲染和双目立体视觉技术，首先使用双目立体视觉求解视频帧刚体变换和粗粒度表情系数，然后使用三阶段可微渲染优化出每一帧的精细表情系数和漫反射贴图，主要包括人脸双目立体视觉 (§ 4.3) 和三阶段可微渲染 (§ 4.4) 两个模块，完成任意光照条件的适应和高保真人脸动画，算法概览见图 4.3。




图 4.3 算法概览图

首先，算法会对于每个新的光照条件提取出中性表情帧，并利用人脸双目匹配网络和点云配准将采集的原尺寸中性表情模型对齐到拍照时的位姿 (§ 4.3.2)，然后进行可微渲染优化出对应场景的光照 (§ 4.4.1)，并执行三阶段可微渲染得到新中性表情的模型和新中性表情的漫反射贴图 (§ 4.4.2)，此阶段得到的模型将参与人脸动画阶段的人脸双目匹配网络 (§ 4.3.3)，得到的环境光和贴图将参与人脸动画阶段的三阶段可微渲染 (§ 4.4.2)。在正式的面部表情捕捉时，视频的每一帧会依次通过人脸动画阶段的人脸双目匹配网络和三阶段可微渲染，得到每一帧的模型和漫反射贴图，进行输出。

4.3 双目几何约束的初值估计

本节先介绍了人脸双目匹配神经网络的网络设计以及训练 (§ 4.3.1), 接下来介绍了使用该网络进行光照适应阶段的对齐采集模型与视频的位姿 (§ 4.3.2), 再介绍了使用该网络进行人脸动画阶段的刚体变换和表情系数初值求解过程 (§ 4.3.3)。

4.3.1 人脸双目匹配神经网络

根据 2.1 节的描述, 已知两个视角的相机参数, 并找到两个视角下匹配的对应像素, 便可通过视差原理得到像素对应的深度信息, 重建点云, 获得两个视角下对应像素的精准匹配是该流程的重点, 本小节针对人脸这个图案相似且重复图案众多的匹配任务, 使用了目前学术界效果领先的稠密特征匹配网络, 并修改了部分网络结构以完成亚像素级别的人脸匹配点寻找, 且在自主构建的人脸数据集上进行了网络的微调, 可在不带显式标记点的人脸上得到数千个正确的几何点。

如图 4.4 所示, 本小节使用的基座网络 LoFTR^[9] (Local Feature TRansformer) 基于目前流行的 Transformer 架构, 网络由特征提取模块和匹配模块两个主要部分组成, 在特征提取阶段, LoFTR 使用卷积神经网络提取图像的多尺度特征图, 并通过 Transformer 的自注意力机制融合多层次特征, 可捕捉长距离的图像依赖,




图 4.4 LOFTR 网络结构^[9]

面部相同特征可能在不同图像中位置变化较大, 传统方法容易忽略远距离特征之间的关系, 而 LoFTR 通过自注意力机制将整幅图像的特征信息融合, 使得它能更

好地理解全局上下文；在匹配阶段，LoFTR 利用由粗到细的匹配设计，先在粗粒度的特征图层级匹配出对应的图像块，再对每个粗粒度的图像块以中心像素为待匹配像素，寻找另一张图片中已匹配的对应像素块中的匹配像素。与传统方法不同，LoFTR 不依赖于显式的特征点检测和描述符计算，而是通过端到端学习直接从图像对中进行精确匹配，从而在处理复杂场景时展现出较高的鲁棒性和精度。

通过点云优化模型的方法中，一种是使用双线性插值将各个点投影到模型布线上的点，一种是只生成由模型布线上的点构成的点云，相比前者来说，后者在流程上更直接，所以本章希望使得 LoFTR 可以指定模型上的每个几何点进行匹配，而不是匹配图像上任意像素，结合网络结构，通过对图 4.4 中 Match Module 部分的更改，将原网络中 5×5 像素块的中心像素与右图匹配，更改至指定 5×5 像素块中某个坐标像素与右图匹配，通过计算模型几何点投影到图片中的像素坐标，即可指定匹配的对象。为得到图像上模型几何点的分布，且匹配两个视角下这些几何点的视差，如图 4.5 所示，参与该算法的视频帧有中性表情帧 $\{I_0^v\}$ 和其他帧 $\{I^v\}$ ， v 表示视角，本算法先匹配中性表情帧 I_0^0 与同一视角下的其他帧 I^0 ，获得 I^0 上几何点的分布，再匹配视角 I^0 与视角 I^1 ，获得这些几何点在两个视角下的视差，以计算深度，其中中性表情 I_0^0 的几何点的分布可以通过已知的中性表情的模型投影到图片上获得，图 4.5 中的每一条红线代表了一对匹配，从 I_0^0 到 I^0 到 I^1 即为完成




图 4.5 人脸双目匹配结果

一次匹配，在匹配时会将竖直方向偏差大于 50 像素的匹配对予以剔除，同时会将重建后深度在平均值 50 毫米以外的点予以剔除，以排除明显错误的匹配结果，由此可获得大约 1000 组 I_0^0 到 I^0 到 I^1 的有效匹配（图 4.5 仅展示了部分匹配）。

但是仅一千个点的点云过于稀疏，尚不足以约束人脸的表情和位姿，如图 4.6 所示，黄点是匹配出的点云（左图），将其与正确的几何对齐来看（右图），仅有稀疏的少量几何点获得了匹配，难以用来优化刚体变换和表情系数，这说明，只使用预训练的通用模型难以对人脸这个特定场景有理想的效果，还需要在人脸数据集上微调（**finetune**），以获得最佳的结果。




图 4.6 预训练模型匹配结果




图 4.7 简易立体视觉采集重建设备

为得到精确的全脸几何和深度，我们参考 Beeler 等人^[19]的思想，设计了一套多目立体视觉采集重建设备，如图 4.7 所示，在使用该设备采集重建完每个视频

人物的角色后,我们将其保留下来,累计出二百余个角色的三维模型,包括男生、女生、老人、小孩,以及胖脸、瘦脸、长脸,还有带妆以及不带妆等各种类别,覆盖常见的所有情况,使得数据集对人脸的匹配有更强的普适性和鲁棒性,并通过渲染器得到正前方屏幕左右两个视角的人脸深度图,由于每个相机的相机参数已知,所以可以方便地进行深度的渲染,得到深度图之后,结合相机参数,即可计算两个视角下像素的匹配关系。

为扩大数据量,同时减小每个数据条目的大小,减少显存的开销,对于每个深度图,进一步地进行了随机裁切,拍摄的每张原图分辨率为 3840×2160 ,将每张深度图中的人脸部分提取出来,分辨率大小为 2400×1800 ,此时将每张图随机裁切成 640×640 的分辨率大小的图像块,左右两个视角以同样的像素坐标为起点,开始进行裁切,最终获得了 100 万张图片。以室外数据集为预训练模型,以上述制作的数据集为模型微调数据集,对修改后的 LoFTR 网络进行训练,最终获得的人脸双目匹配模型可得到四千余对匹配,可以完全满足刚体变换优化和表情系数的初始估计任务,由此微调后的模型计算出的点云如图 4.8 所示,左图黄点是匹配出的点云,右图是其与正确的几何对齐的分布情况。




图 4.8 微调后模型的匹配结果

4.3.2 视差重建点云

人脸双目匹配神经网络在整个算法中共有两个作用，一个是重建出点云用来将采集重建时的原尺寸的模型与视频中的初始位姿对齐，一个是在正式视频求解中用来优化位姿和表情系数，本小节主要讨论第一种应用。

采集重建的中性表情与视频里的中性表情有很高的相似度，所以可以不使用最小二乘优化的方法，可以直接使用 ICP (Iterative Closest Point, 迭代最近点) 将原尺寸模型重建出的点云与视频帧重建出的点云进行对齐，为准确且方便地进行脸部区域选取，此时应用人脸双目匹配神经网络时，不需要匹配点与模型布线的点重合，使用 LoFTR 原网络架构和微调后的模型进行点云重建，即可用于 ICP 配准，图 4.9 显示了采集时和视频帧的原图和点云重建结果。其中，将一对匹配




图 4.9 采集时和录制视频时的中性表情的重建结果

通过立体视觉技术得到深度基于三角化实现，三角化方法常用于 SLAM 中，用于从两个或多个视角观察到的 2D 图像点中恢复出 3D 空间点的坐标，其在 opencv 库中有 `triangulatePoints` 的函数实现中，主要包括三个步骤，首先利用两个视角中观察到的 2D 点和相机的投影矩阵来构建一个设计矩阵，接下来对设计矩阵进行 SVD 分解，找到与最小奇异值对应的奇异向量，该向量即为 3D 点的齐次坐标，最后将 3D 点的齐次坐标转换为非齐次坐标，即将最后一个坐标除以所有坐标，得到实际的 3D 空间点坐标。在得到两组点云之后，将通过点到点的 ICP 配准进



图 4.10 ICP 配准采集的中性表情的点云与视频的中性表情的点云

行对齐，ICP 的输入是两个点云和一个初始转换，初始转换大致将源点云与目标点云对齐，输出是一个精细化的转换，它将两个点云紧密对齐，核心思想是最小化源点云和目标点云之间对应点的欧氏距离，通过不断迭代更新变换矩阵，算法使源点云和目标点云之间的误差逐渐减小，最终达到收敛。如图 4.10 所示，两个原来间隔较远的点云（图 4.10 上图），通过 ICP 配准，即可接近于重合（图 4.10 下图），将该变换应用于模型上，即可将采集时的原尺寸模型与视频帧的模型对齐。

4.3.3 基于点云优化刚体变换及表情系数

本小节主要讨论使用该人脸双目匹配神经网络进行人脸动画阶段的刚体变换和表情系数初值求解。基于双目匹配网络，可以使得任意夸张表情都获得四千余组有效匹配，也已经可通过重建出的点云判断出大致的表情。

本小节使用的双目匹配网络使用光照适应阶段的渲染结果图片作为布线参考图片，由于此时渲染结果已与原视频帧高度接近（如图 4.11），人脸双目匹配网络可以将此图与表情帧匹配得到足够的匹配对，而将采集时的原图与表情帧匹配会因为光照不同、相机位置不同、拍摄时皮肤状态不同、相机传感器不同导致的人脸差异（如图 4.12）而无法建立匹配，当每次光照发生剧烈变化时，光照适应阶段会重新计算此时的布线参考图片，即可保证任意光照条件下，人脸双目匹配网络都可获得足够的匹配组合，使得算法可以在任意光照条件下鲁棒运行。



图 4.11 原视频帧与光照适应阶段可微渲染最终渲染结果对比



图 4.12 视频帧与采集时光照、位姿、皮肤状态、相机色彩差异对比

除使用点云求解之外，还需要一个基于图片的辅助约束项——人脸特征点约束帮助算法快速收敛。人脸特征点约束项通过比较人脸特征点检测工具预测的人脸特征点与待优化模型对应顶点的投影来进行，对于每个视角 v 的图片，通过Google的MediaPipe库^[44]检测出40个特征点 $\{L_k^v\}$ 对应眼角、鼻尖、嘴唇等（详见图4.13），然后对于每个特征点 k ，从模型上找出其对应的顶点序号 l_k 并计算2D面部特征点与其对应的顶点的投影的二范数距离，见公式4.4，式中 M^v 为模型通过§4.1节中的公式4.1计算到的在对应视角下的投影。

$$E_{land}(p) = \sum_{v,k} \|L_k^v - M_{l_k}^v\|^2 \quad (4.4)$$



图 4.13 人脸特征点位置示意

由此，该步骤优化项的设计如公式4.5所示， $\overline{P_k}$ 为重建出的点云， $\widetilde{P_k}$ 为表情系数 z 运算得到的模型上的第 k 个顶点， λ_{land} 为人脸特征点约束项的权重，同时优化刚体变换平移参数 t 和四元数 r 以及表情系数 z ，使用Adam^[30]优化器求解，经过200次迭代，可完成收敛，可将视频帧各表情优化出一个大致的形状，由图4.14的对比图和色温图可以看出，各模型的位置已完全对齐拍摄时的位姿，大多数区域的误差都在 $[0,0.5]$ 以内，表情也有了大致的形状，此步骤得到了完全正确的刚体变换，在可微渲染时就可不优化刚体变换，大大增加可微渲染收敛的几率。

$$\min_{r,t,z} \sum_k \|\widetilde{P_k} - \overline{P_k}\| + \lambda_{land} E_{land} \quad (4.5)$$




图 4.14 本节优化得到的模型与真实模型的对比

4.4 三阶段可微渲染

本节先介绍了如何使用球谐光照和参数化光照贴图应对复杂变化的光照条件 (§ 4.4.1)，而后利用由粗到细的优化架构，使用三阶段可微渲染，实现精准迁移各种精细的面部表情，并串联了本章所有步骤，给出了最终结果 (§ 4.4.2)。

4.4.1 光照建模

光照条件的变化对物体的外观表现有很大的影响，根据渲染方程(公式 2.5)和路径追踪的原理，逆向光线从每个像素出发，与物体表面发生作用，在经过多次弹射后，最终打到环境光上为止，这其中不同的环境光照和不同的观察角度都会使同一物体表现出不同的外观表现，利用可微渲染来求解物体的几何，首先需要正确建模出光照和观察角度对外观的影响，否则将难以收敛。

使用球面谐波函数(简称球谐函数)来模拟环境光照最早用在实时渲染中，它的思想是利用球谐基函数将光照信息(例如环境光照)展开成一组基函数的线性组合，从而可以用较少的系数表示复杂的光照环境，本节意图通过计算出恰当的球谐光系数来还原环境光照，使用球谐函数生成环境光的表达式为公式 4.6， c_{lm} 为球谐光系数， Y_{lm} 是球谐光是球谐基函数，它是一组定义在球面上的正交函数，或是说球面上的任何函数的一种“投影”基，类似于在平面上用傅里叶基函数展开一个信号，球谐基函数提供了球面上的正交分解，通常前三阶即可基本

$$L(\theta, \phi) = \sum_{l=0}^N \sum_{m=-l}^l c_{lm} Y_{lm}(\theta, \phi) \quad (4.6)$$




图 4.15 前四阶球谐基函数示意图

还原光照信息，其计算过程已集成在 `scipy.special.sph_harm` 等函数库中，此处不展开叙述，其示意图见图 4.16， Y_{lm} 在此次还原环境光中使用的最大阶数为 N ，最后生成的 $L(\theta, \phi)$ 即是环境光照在给定方向上的强度。不同的球谐光系数可重建出不同的环境光，不同的球谐光系数恢复出的环境光，以同样的视角打在同样材质的人脸上会产生明显不同的外观表现，通常通过优化前三阶球谐光系数，即 $l=0, l=1, l=2$ 三阶，共 9 组系数，每组系数包含 RGB 三通道，共 27 个参数，即可大致模拟出较低频的环境光照信息，而大多数情况下环境光照都是低频的，低频环境光照足够表现自然界的光照条件，甚至如果强行使用太高频的环境光照还容易在执行优化几何或贴图任务时，会将本不该属于环境光的信息混合进环境光中，阻碍几何或贴图的优化过程，所以本章只求解前三阶球谐光系数。

通过 § 4.3.3 采集的等比例中性表情模型和拍摄位姿的对齐，可以直接用可微渲染固定刚体变换和表情系数求解三阶球谐光系数，本章球谐光的系数已归一化到了 $[0,1]$ ，将初值设为 $0.1_{3 \times 9}$ ，使用 Adam 优化器以 0.01 学习率迭代 200 次即可收敛，当光照条件不发生剧烈变化时，即可用此球谐光系数通过公式 4.6 得到环境光贴图，参与三阶段可微渲染流程。

同时由 § 2.2 节介绍的人脸反射属性研究中可知，人脸不仅包含各向同性的漫反射材质，还包含各向异性的镜面反射等材质，甚至还有次表面散射等更复杂的材质，从只考虑漫反射材质，到添加镜面反射材质，与拍摄原图的相似程度有显著的提升，在这些材质的共同作用下，若待优化的参数只是漫反射材质和几何，那可微渲染的流程将很难收敛，然而镜面反射和次表面散射建模难度巨大，使用基于物理的渲染来高保真还原人脸一度还是工业界的难题，如何简便地处理好人脸的镜面反射和次表面散射等各向异性的材质属性，对高效完成优化任务起着决定性的作用。

为此, 本文使用了一种参数化的建模, 来配合可微渲染优化光照贴图和漫反射贴图两种不同类型的贴图来解决问题。如公式 4.7 所示, 本文借鉴最近域转换

$$\hat{T}^v = T \odot G^v + B^v \quad (4.7)$$

的相关工作, 对采集重建的中性表情的漫反射贴图施加颜色变换, 式中 $G^v \in \mathbb{R}^{3 \times w \times h}$ 和 $B^v \in \mathbb{R}^{3 \times w \times h}$ 分别称为 **gain** 和 **bias** 贴图, $\odot$ 是元素乘符号, 指两个形状相同的矩阵按对应元素数值相乘, $\hat{T}^v$ 即为新生成的贴图, 使用 **gain** 和 **bias** 配合的方式不仅可以更快地成倍变换, 加快收敛, 还支持精细调整, 最终合成的 $\hat{T}^v$ 拥有连续性和广阔的表示范围, 从原理上来说, 通过优化 **gain** 和 **bias** 贴图, 总可以使得用该贴图贴在人脸渲染出的结果与真实照片完全相同。然而使用这样的设计, 理论上这两张贴图不仅可以包含光照信息, 同时还强大到可以补偿几何的错误, 且每个视角都优化一组 **gain** 和 **bias** 贴图, 也不能支持重光照和切换视角。


为解决以上问题, 结合双目的配置和漫反射各向同性的原理, 依据漫反射材质在各个角度观察都相同的事实, 本文通过在两个视角下优化同一组 **gain** 和 **bias** 贴图, 如公式 4.8, 即可使 $\hat{T}$ 符合漫反射的各向同性, 支持切换视角, 将 $\hat{T}$ 与 T 贴在同一个模型上并在同一个视角观察, 与原图相比, $\hat{T}$ 贴在模型上重新渲染与原图有更高的相似度, 用这种建模方式会让可微渲染的收敛更容易, 同时通过实验观

$$\hat{T} = T \odot G + B \quad (4.8)$$

察, 控制 **gain** 和 **bias** 贴图的值尽可能地小, 在优化过程中给 **gain** 和 **bias** 关于其初值的均方误差损失设置惩罚项, 即保证非必要只保持 T 的信息, 还可利用 T 完全的漫反射性质, 让 $\hat{T}$ 在一定程度上支持重光照, 如图 4.17 是 $\hat{T}$ 贴在人脸, 将光照



图 4.17 将 $\hat{T}$ 贴图在人脸渲染的结果重光照

图 4.18 $\hat{T}$ 贴图与采集重建的漫反射贴图的差异

切换成摄影棚采集的光照，并让光源持续进行水平移动，使用的表情为视频帧中优化出的微笑的表情，在渲染引擎中进行渲染得到的结果，从图中可以看出， $\hat{T}$ 有很明显且逼真的重光照效果， $\hat{T}$ 已经拥有了漫反射贴图的一些性质，此时将优化后的 $\hat{T}$ 贴图输出出来可以发现，其包含了录制视频时和采集重建时人物皮肤的不同状态，包括痘印等，由于录制视频时，人物的皮肤状态不可避免会发现变化，而重新采集又费时费力，所以该部分对于算法的实用性来说至关重要， $\hat{T}$ 贴图见图 4.18，由图中还可以看出，其除了包含痘印等细节，也不可避免地包含了部分在两个视角下相同的光照信息，如鼻角附近由于视角的覆盖范围原因，此部分未能完全去除光照，除此之外，还包含发际线部分以及口腔内部等细小瑕疵，这些可通过简单的剪切并以 T 填充来处理。

然而由于两个视角不可避免会有不同的镜面反射，如图 4.19，两个视角的亮部位于不同的区域，为努力实现彻底收敛，对此可近似使用低频的光照贴图来表示这种差异，相比于面部的斑痕或痘印来说，区域高光更为低频，所以可以使用较低分辨率的 *gain* 和 *bias* 贴图（1/16 分辨率于 T ），通过三线性插值上采样到原图分辨率，即可表示两个视角的光照信息， $\hat{T}_{light}^v$ 公式见公式 4.9，随后建立在此两个视角不同高光的基础上，即可对各向同性的 $\hat{T}$ 进一步优化，见公式 4.10。

$$\hat{T}_{light}^v = T \odot \text{Upsample}(G^v) + \text{Upsample}(B^v) \quad (4.9)$$

$$\hat{T}^v = \hat{T}_{light}^v \odot \text{Upsample}(G) + \text{Upsample}(B) \quad (4.10)$$



图 4.19 两个视角亮部区域的对比

4.4.2 面部表情求解




图 4.20 三阶段可微渲染流程图

三阶段可微渲染的流程如图 4.20 所示，流程的初始输入为 § 4.4.1 得到的球

谐光系数, § 4.3.3 得到刚体变换 R 和表情系数的初值 z , 参数化贴图的初值 $G = \mathbf{1}_{3 \times 128 \times 128}$, $B = \mathbf{0}_{3 \times 128 \times 128}$, 采集重建得到的中性表情漫反射贴图 T 以及当前视频帧两个视角的图片 $\{I^v\}$, 最终输出为图中绿色框所示的几何和贴图。整个流程基于可微渲染, 由虚线框分割出了三部分, 优化结果从左往右流动, 组成了三阶段可微渲染, 图中填充框为待优化的变量, 即在可微渲染中存在梯度, 空白框为常数, 不含梯度。首先, 球谐光系数生成的环境光贴图、表情系数初值和刚体变换生成的模型、 G_1 和 B_1 贴图与 T 通过公式 4.8 运算得到的贴图三部分一起进入可微渲染流程, 通过路径追踪可微渲染渲染出的图片与输入的两个视角图片计算图像损失, 收敛后将模型和贴图传入第二阶段, 此时待优化的贴图为光照贴图 $G^v \in \mathbf{1}_{3 \times 32 \times 32}$ 和 $B^v \in \mathbf{0}_{3 \times 32 \times 32}$, 与上一阶段得到的 T' 通过公式 4.9 运算得到两个视角的贴图 T^v , 把两个贴图分别贴到上一阶段传入的模型, 在环境光照 L 下进行第二阶段可微渲染, 收敛后将优化得到的两张贴图 T^v 传入第三阶段, 该阶段的待优化参数为表情系数 $\tilde{z}$ 和 $G_2 \in \mathbf{1}_{3 \times 256 \times 256}$, $B_2 \in \mathbf{0}_{3 \times 256 \times 256}$ 贴图, G_2 和 B_2 贴图分别与 T^v 通过公式 4.10 运算得到两个视角的贴图 $\hat{T}^v$, 贴到由表情系数和刚体变换生成的模型上, 在环境光照 L 下进行第三阶段可微渲染, 收敛后将优化得到的 G_2, B_2 与第一阶段生成的 T' 通过公式 4.10 运算得到最终的贴图 $\hat{T} \in \mathbb{R}^{3 \times 1024 \times 1024}$, 该阶段生成的模型和贴图 $\hat{T}$ 即可输出, 供实时渲染引擎渲染或者重新打光后渲染。具体的执行细节见算法 2:

算法 2 三阶段可微渲染

输入: 视频帧 $\{I^v\}$, 检测到的人脸特征点 $\{L_k^v\}$

输出: 表情系数 z

步骤 1: $z, G, B \rightarrow \arg \min_{z, G, B} E_{RGB} + \lambda_{reg} \|G\| + \lambda_{reg} \|B\| + \lambda_{land} E_{land} + \lambda_{ct} \|z - z_{last}\|$

步骤 2: $G, B \rightarrow \arg \min_{G, B} E_{RGB}$

步骤 3: $z, G, B \rightarrow \arg \min_{z, G, B} E_{RGB} + \lambda_{reg} \|G\| + \lambda_{reg} \|B\| + \lambda_{land} E_{land} + \lambda_{ct} \|z - z_{last}\|$

算法 2 中的 E_{RGB} 为图像 RGB 损失, $\lambda_{reg} \|G\|$ 和 $\lambda_{reg} \|B\|$ 用来限制 gain 和 bias 贴图的值尽可能地小, 即保证非必要只保持原有贴图的信息, $\lambda_{land} E_{land}$ 用来加速收敛, 并借助特征点检测的时域稳定性保持每帧之间的几何结果不会有跳变, $\lambda_{ct} \|z - z_{last}\|$ 使该帧表情系数与上一帧表情系数不要有太大差别, 同样用来保证

相邻帧几何的连续性, 保证时域稳定(优化第一帧及光照适应阶段时, z_{last} 为 0)。经过实验, 当算法 1 中的 λ_{reg} 为 0.1, λ_{land} 为 10, λ_{ct} 为 0.01 时, 优化策略选择 Adam 方法, 步骤 1 的学习率为 0.005, 步骤 2 的学习率为 0.005, 步骤 3 的学习率为 0.001, 均最多迭代 50 次, 可微渲染采样率设为 16spp (samples per pixel, 每像素样本数) 时, 算法可获得最佳结果, 同时, 为加速收敛, 图 4.3 光照适应阶段的迭代次数设为固定的 50 次, 人脸动画阶段当此时图像 RGB 损失小于光照适应阶段时的值时即停止优化 (如光照适应阶段的第一阶段可微渲染第 50 次收敛时的 RGB 损失为 0.0145, 则人脸动画阶段的第一阶段可微渲染第 50 次收敛时 RGB 损失小于等于 0.0145 时即停止优化), 本文算法用到的所有视频帧, 均会先将原视频经过人脸区域分割算法^[29]过滤背景、发际线和口腔内部后使用, 过滤的遮罩见图 4.21 右图, 白色的区域为保留的区域, 黑色的区域为抹去的区域。




图 4.21 人脸区域分割遮罩

回顾本章所有步骤, 当算法第一次启动或光照条件发生变化时, 光照适应阶段触发执行, 首先算法对中性帧重建出稠密点云, 并与原尺寸模型对齐 (§ 4.3.2), 接下来使用可微渲染求解环境光, 使得从环境光初值时的图 4.22(b)照亮为图 4.22(c), 并得到此光照的球谐光系数, 从图 4.22(d)的初值即上图优化得到此环境光的球谐光系数即下图, 后续帧将会使用此环境光照进行可微渲染求解。




图 4.22 求解环境光步骤

下一步让球谐光系数和表情系数初值零进入第一阶段可微渲染,随后依次完成第二阶段、第三阶段可微渲染,得到新的中性表情 M_{neu} 和贴图初值 T ,图4.23展示了第一阶段以及第二、三阶段可微渲染完成的中间结果,本文还解算了眼球的贴图,以使动画时的眼睑动作解算可以获得收敛,眼球由于两个视角下会有反光的不同,解算时分别计算了两个眼球在两个视角下的共四张贴图,如图4.24所示。




图 4.23 可微渲染中间结果




图 4.24 眼球解算贴图

人脸动画阶段,对每帧视频,算法会将光照适应阶段得到的渲染结果与视频帧进行双目匹配,供匹配布线的原模型即为光照适应阶段得到的新的中性表情 M_{neu} ,通过人脸双目特征匹配网络以及三角化,即可重建出可确定位姿和大致表情的点云,接下来将该点云和检测出的40个面部特征点一起梯度下降200轮(§4.3.3),得到三阶段可微渲染的初值,将光照适应阶段求解的环境光、贴图初值 T 和上一帧的表情系数传入人脸动画阶段的三阶段可微渲染,生成该帧最终的模型和贴图(渲染结果见图4.25(b),模型见图4.25(c),贴图见图4.25(d)),最后将该帧的表情系数传入下一帧用于时域稳定性约束,当帧的面部表情求解就全部完成了。由此逐帧计算,即可完成整个视频序列的表情解算,并且当光照发生剧烈变

化时，算法可立刻适应新光照，当提取出新光照的中性表情帧进行光照适应后，可继续解算剩余帧，如图 4.26 所示，当右侧视频帧光照相比左侧发生了剧烈变化后，剩余片段仍可无缝衔接。




图 4.25 解算最终结果




图 4.26 算法对于光照变化的适应展示

4.5 本章小结

本章针对复杂光照条件下面部表情精准迁移的技术难题，提出了一种融合双目立体视觉与可微渲染的高保真面部表情捕捉方法。该方法先通过立体视觉获得单目配置无法准确测定的刚体变换，以及表情系数的初值，后通过可微渲染对表情系数进行精细优化，通过分层级优化策略，有效解决了刚体运动分离、光照解耦及表情细节还原等关键问题，具体创新点及贡献如下。第一，构建轻量化双目采集系统，结合张正友标定法实现高精度相机校准，开发包含 200+ 角色的多维度人脸数据集，为算法训练提供充足支撑。第二，改进 LoFTR 网络实现 4000+ 特征点匹配，结合三角化算法构建带法线信息的 3D 点云，为刚体变换估计提供几何约束。第三，设计三阶段优化框架，通过粗粒度配准、光照解耦和精细化贴图优化，实现表情系数与光照参数的有效分离，支持动态光照切换和微表情还原。

第5章 实验结果与分析

本文对高保真人脸动画，基于逐层级计算得到了一套面部骨骼绑定，后基于可微渲染及立体视觉使用该绑定从双目视频中得到了人脸动画，前文中已经展示了面部骨骼绑定的结果和人脸动画还原的效果，本章将对人脸动画的还原度进行定量分析，并与其他方法进行对比，然后对算法流程中的重要方法进行消融实验，以证明各关键部分在保证人脸动画高保真中的意义与真实价值。

5.1 实验配置

本文实验的运行环境见表 5.1。

表 5.1 实验运行环境

运行环境	
CPU	AMD RYZEN 9 5900HX
RAM	32GB
GPU	NVIDIA RTX 3080
操作系统	Windows 11 专业版

为得到人物高精度的中性表情的三维模型、漫反射材质以及表情基的三维模型，我们使用了一个大型的多相机采集重建装置，如图 5.1 所示，其包含 12 个不同视角的单反相机以及屏幕两侧下方两个 Kinect 摄像头，每次采集时会用所有相机同时拍摄出 6960×4640 像素的高清照片并进行校色，每个相机前加设的偏振片与光源前加设的偏振片方向垂直，相机对焦后用户会根据提示做出中性、微笑、张嘴、撅嘴、左嘟嘴、右嘟嘴、闭眼、抬眉八个表情，采集后会使用标定球进行相机标定，采集耗时在两分钟以内。




图 5.1 采集重建设备

视频录制使用 § 4.1 节的图 4.1 的设备, 本文对总共 42 个角色进行了视频录制、面部绑定和表情解算, 所有参与实验的角色见图 5.2, 每个角色被指示说出一段话, 中间会有眼神交流等细节神态, 之后会做出狰狞、皱眉等夸张表情, 中途会进行开关灯以及关闭、打开窗帘等变换环境光照的操作。每个角色均以 60FPS 的帧率录制了 3 分钟的面部动画视频, 共计 10800 帧, 并对其进行解算。




图 5.2 参与实验的所有角色

5.2 效果评估

图 5.3 展示了本文算法对蹙眉、抬眉、撇嘴、大幅张嘴、挤眼等极端表情以及眼神交流、微笑、紧张等细节神态的还原度，每个表情第一列为原视频帧，第二列为还原表情。由图可以看出，本文算法对于极端表情，不仅可以准确还原表情的幅度，还可以重现皱纹等更高频的细节，对于细节神态，数字人重演的表情神态可以高度拟真本人的表情神态，准确地表现出了本人的眼神交流、微笑以及紧张等神态。



图 5.3 极端表情和细节神态原图与还原结果对比

图 5.4 展示了某角色讲一段话的原视频与还原结果的对比，每栏的第一列为原视频帧，第二列为还原结果，从图中可以看出，生成的数字人动画与原视频有较高的还原度，且生成的数字人动画可以保证良好的时域稳定性。



图 5.4 连续帧原图与还原结果对比

在算法的时间复杂度上,图 5.4 前五帧的算法执行时间如表 5.1 所示,由于使用基于路径追踪的可微渲染,开销较大,所以算法只能采用离线的方式解算,从表中可以看出,平均每帧的计算可以控制在一秒以内,由于第一帧从初值零开始计算,而后续帧可依据前序帧做初值,所以第一帧会有较长的耗时。通过对所有视频帧进行全量计算,本文算法平均每帧的解算时间为 0.68s,一段以 60fps 拍摄的 1 分钟的视频,使用约 0.7 小时完成解算,虽不能达到实时,但相比对每帧进行几何重建或者涉及大量人工的电影制作流程有显著优势。

表 5.2 前五帧执行时间(单位:秒)

	人脸双目匹配阶段	一阶段可微渲染	二阶段可微渲染	三阶段可微渲染
帧 1	0.21	0.33	0.22	0.29
帧 2	0.22	0.12	0.05	0.13
帧 3	0.19	0.16	0.03	0.16
帧 4	0.20	0.13	0.04	0.13
帧 5	0.21	0.12	0.05	0.16

本文算法由于使用基于传统图形学的优化策略,生成的资产可以保持重新光照和切换视角等良好的后期编辑特性。如图 5.5 所示,因为本算法是基于多边形网格的优化,算法生成的结果在任何角度均无瑕疵。同时由于生成的贴图基本保持了漫反射材质的特性,切换强光、弱光时可以呈现明显的重光照效果,且重光照的效果具有良好的保真度。




图 5.5 生成资产的后期编辑特性

算法对比评估部分,我们将本文算法与其他前沿的基于多边形网格进行人脸动画的方法进行了定性和定量对比,包括 Zielonka 等人于 2022 年提出的 MICA^[2],以及 Epic Games 于 2023 年开发的 MetaHuman Animator。比较的主要指标是图像还原度以及几何还原度。其中图像还原度采用 PSNR、SSIM 和 LPIPS 三种指标,在比较图像还原度时,由于 MICA 和 MetaHuman Animator 仅优化几何而不优化贴图,所以为控制变量,比较时将这两者也贴上了光照适应阶段得到的贴图,在图 5.6 中列出了角色的部分极端表情实验结果。



图 5.6 MICA、Animator 与本文算法结果的对比

对于挤眼表情来说, MICA 的结果眼睛的闭合程度不够,且嘴巴的倾斜幅度没有很到位,这是由于 MICA 过多依赖了特征点的约束,特征点在其算法中有很高的权重,而特征点检测算法对于嘴巴如此大的变形难以有效捕捉,特征点检测

算法训练的数据集中大多是日常说话涉及的表情，对于夸张的表情由于训练所需的人工标注成本的原因无法很好的覆盖，使得特征点的权重不宜过大，本文的特征点与图像 RGB 损失的权重比例相比于 MICA 少了 10 倍，减小了特征点检测误差对结果造成的影响，虽然 Animator 并没有开放论文及源代码无法从理论上分析，但从观感上来看，Animator 的嘴部和眼睛的还原度远低于本文算法；对于狰狞表情来说，MICA 并没有将嘴部嘟起的细节还原到位，同时由于其没有优化贴图，而眉头的皱纹很难通过几何表示，所以眉头紧皱的细节只能做出大致形状，而本算法通过优化贴图，精准地还原了眉头紧皱的细节，对于 Animator 来说，虽然其使用了与本文相同的动态贴图设计，其眉头紧皱相比于 MICA 来说有些许提高，但其贴图的自由度不够，不能一比一还原眉头紧皱的细节；对于大笑表情来说，由于 MICA 使用 Flame 三维可形变空间，该空间的表情系数是通过大量先验生成的，没有很好满足本人的特征，对于这种咧嘴笑来说没有很好覆盖，而 Animator 只使用 Creator 获得的绑定进行面部表情捕捉，对于本人的特征还原度不够，无法一比一还原本人的表情特点，使得该帧的 Animator 的嘴部无法做到原视频帧中的圆润度，主要通过咧开嘴来尽力模拟嘴部的弧度。

定量数据可以更为直观地反映动画的重演质量。本文的定量实验选取了三个对比图像重建的常用指标——PSNR、SSIM 和 LPIPS。PSNR（峰值信噪比，Peak Signal-to-Noise Ratio）表示原始图像与生成图像（重建图像）之间的像素级误差，通过计算原始图像与待评估图像之间的均方误差，并将其转换为对数尺度，来衡量图像的质量，常作为应用场景可用性的评判标准。SSIM（结构相似性指数，Structural Similarity Index Measure）用于衡量两幅图像之间的结构相似性，通过比较参考图像和待评估图像的亮度、对比度和结构信息，计算它们的相似性。LPIPS（Learned Perceptual Image Patch Similarity）是一个基于深度学习的感知质量指标，关注两幅图像在局部视觉细节上的相似性，对视觉伪影、纹理变化等问题更敏感，往往被认为是最接近人眼感知的指标。表 5.3 中列出了三个指标的通用标准。

表 5.3 PSNR、SSIM 和 LPIPS 的通用标准

	高质量标准	可接受标准	低质量标准
PSNR	$\geq 38 \text{ dB}$	$32 - 38 \text{ dB}$	$< 32 \text{ dB}$
SSIM	> 0.90	$0.80 - 0.90$	< 0.80
LPIPS	< 0.10	$0.10 - 0.25$	> 0.25

本文对三个方法使用 42 个角色各 10800 帧视频计算的结果进行了 PSNR、SSIM 和 LPIPS 三个指标的定量对比, 对比时原视频与解算结果作用了同样的背景和口腔的遮罩, 表 5.4 列出了实验的结果。

表 5.4 动画重演精度数值对比

	PSNR↑	SSIM↑	LPIPS↓
MICA	32.91	0.876	0.183
MetaHuman Animator	35.86	0.891	0.112
本文算法	37.93	0.959	0.076

从表 5.4 的实验数据可以看出, 本文提出的算法在 PSNR、SSIM 和 LPIPS 三个关键指标上均显著优于 MICA 和 MetaHuman Animator, 说明该方法在动画重演的视觉质量、结构相似性和感知相似度方面均有较大提升。在 PSNR 上, 本文算法 (37.93 dB) 比 MICA (32.91 dB) 高出 5.02 dB, 比 MetaHuman Animator (35.86 dB) 高出 2.07 dB, PSNR 值越高, 说明重建图像与原始图像的像素级误差越小。在影视动画中, 角色常处于动态光照环境 (如日光、霓虹灯、火光), 传统方法容易因光照估计不准导致材质失真或光照不自然等“塑料感”现象, 38 dB 以上的 PSNR 通常意味着极高的图像保真度, 接近人眼难以察觉差异的水平, 可适用于电影级特效 (如《阿凡达》级别的数字角色), 37.93dB 的 PSNR 表明本文算法在细节还原 (如皮肤纹理、光照变化) 方面表现优异, 该技术已接近影视工业的准入标准, 为人脸表情重演克服材质、光照、动态细节三者与生物学现实的偏离, 推动工业化落地提供了可能。SSIM 衡量的是图像在结构信息上的相似性, 0.95 以上的 SSIM 表明本文算法能更好地保留人脸的关键结构特征, 如五官轮廓、表情动态, 减少形变或模糊现象。LPIPS 是基于深度学习的感知相似度指标, 能更好地反映人类视觉系统的判断。较低的 LPIPS 值表明本文算法在表情自然度、运动连贯性等方面更优, 减少了人工合成的“虚假感”。通过数值对比可以看出, 本文算法在动画重演的还原度上相较于现有基于多边形表达的算法有显著提升。

接下来进行几何还原度的对比。几何还原度对于切换视角和后期编辑极为重要, 为比较面部表情捕捉的几何还原度, 我们使用已知几何的合成数据来解算面部的动画, 光照采用录影棚的灯光, 使用本文算法、MICA 和 MetaHuman Animator 进行表情的解算, 图 5.7 展示了三种方法解算的几何结果以及与真实几何的色温

图对比，本文算法由于使用基于多边形网格的绑定，并通过双目各向同性材质的约束尽可能地将差异写进了几何内，可以用几何表示的表情细节几乎完全表示在了几何上，并未由贴图做过多的补偿，几何的损失基本保持在 1 毫米以内。




图 5.7 几何还原度展示

表 5.5 列出了几何还原度对比中的详细数值结果。对比内容重建误差的平均值和中值。这两项指标体现了本章提出算法在绝对误差上的优势。此外，还比较了重建结果中误差小于 0.2 mm、0.5 mm 和 1 mm 的部分的比例。从数据来看，本章提出的算法在重建精度上具有明显优势。具体而言，算法的平均误差为 0.703mm，比 MICA 和 MetaHuman Animator 分别降低了 37.8%和 28.3%；中值误差为 0.596mm，同样优于对比方法。对于<0.2mm 的高精度要求，本方法达标率

达到 34.6%，远超对比算法的 13.7%和 21.3%。在<0.5mm 和<1mm 的精度标准下，本方法分别达到 46.1%和 98.5%的达标率。这些数据充分说明，本章算法不仅在整体精度上更优，在细节还原和误差控制方面也更具优势。

表 5.5 几何还原度数值对比

	平均误差 (mm)	中值误差 (mm)	<0.2mm (%)	<0.5mm (%)	<1mm (%)
MICA	1.13	0.882	13.7	36.2	59.6
Animator	0.98	0.799	21.3	41.2	71.2
本文算法	0.70	0.596	34.6	46.1	98.5

除此之外，由于使用支持 MetaHuman 的绑定，本文生成的表情帧可对表情进行重新编辑，将动画序列导入 Maya 后，使用 MetaHuman 设计的控制滑块即可对表情幅度进行编辑，如图 5.8 所示，可将表情幅度由左图增加为右图。




图 5.8 动画序列在 Maya 中的编辑

5.3 消融实验

本文的面部骨骼绑定流程中最关键的部分是让这套绑定定制化地贴合该人的表情空间，一套贴合本人的绑定可以使表情的解算更好收敛，为验证该步骤的必要性，我们使用了初始绑定和个性化表情定制后的绑定对同一段视频进行面部表情解算，对挤眼表情帧进行分析，不进行人脸表情空间计算时，由于表情表示范围不足，如图 5.9 所示，上列挤眼表情的眼睛会完全闭上，无法准确模拟视频帧挤眼的形态，而进行人脸表情空间计算后，表情空间得到了扩充，可以表示出本人眯眼的细节形态。下列张嘴表情的关键帧中，在不使用人脸表情空间计算的情况下，系统对张嘴幅度的优化存在明显偏差，导致嘴部运动无法准确匹配目标表情，从而影响了整体表情的还原质量。具体表现为：嘴部开合程度不足，嘴角形态不自然，然而，在引入人脸表情空间计算后，系统能够更精确地建模嘴部运动的动态特征，包括嘴唇轮廓的形变等。通过表情空间的约束和优化，张嘴动作的幅度、速度以及细节形态（如嘴角的拉伸、嘴唇的厚度变化等）均能得到准确还原，最终实现与真实表情高度一致的三维重建效果。




图 5.9 人脸表情空间计算消融实验

可微渲染的三个阶段彼此相辅相成，缺一不可，当只使用第一阶段可微渲染，而不通过第二、第三阶段可微渲染处理各向异性的部分，得到的结果也会与真实图片有些许差异，如图 5.10 所示，当只使用第一阶段可微渲染，而不使用第二、第三阶段可微渲染时，由于双目视角存在各向异性的镜面反射部分，只考虑各向同性的材质缩小了自由度，算法无法收敛，不能很好地优化表情，PSNR 会直线下降，同时，又由于第二阶段与第三阶段有绑定性，第二阶段可微渲染为第三阶段服务，故三个阶段缺一不可。



图 5.10 三阶段可微渲染消融实验

图 5.11 展示了最大迭代轮数的设计原则，当最大迭代轮数从 10 到 50 时，优化效果有明显的提升，而当最大迭代轮数从 50 提升到 100 时，由于此阶段已基本收敛，所以基本没有效果，故三阶段可微渲染将最大迭代轮数设为 50，同时，由于帧间的连续性，在上一帧优化结果的基础上，有时不需要做出很大的变化，所以本文还设置了中止条件，当与光照适应阶段同期的损失相同时，即可认为算法已收敛，即可立刻进入下一阶段。




图 5.11 最大迭代轮数设计原则

同时, 采样率的不同对渲染图片的还原度有很大的影响, 更高的采样率意味着更少的噪点, 然而采样率过高会导致显卡负荷过重, 通常在 1920×1080 的图片上显存最多支持 16spp 的采样率, 若再期望使用更大的采样率则意味着需要缩放图片到更小的尺寸, 如图 5.12 比较了不同的采样率对结果的影响, 当采样率为 32spp 时, 为满足显存要求, 图像的长宽各进行了一倍的缩小, 由图可见, 当采样率为 16spp 时, 由于图像没有缩放, 图像细节没有丢失, 对原图的恢复有很大的帮助, 当采样率小于 16spp 时由于噪点过多, 可微渲染很难追踪到图像细节, 还原质量也有所下降, 所以本文使用 16spp 的采样率。




图 5.12 采样率设计原则

除此之外, 当不使用人脸双目立体视觉得到刚体变化和表情系数初值, 只使用人脸特征点进行刚体变换预测, 并将刚体变换作为参数交由可微渲染优化时, 可微渲染将完全无法找到正确的刚体变换位置, 刚体变换将与表情系数一起发生剧烈变化, 无法收敛, 所以使用人脸双目立体视觉确定正确的刚体变换, 与表情系数完全解耦, 对可微渲染的收敛尤为重要。如图 5.13 当把刚体变换当作参数加入可微渲染优化过程时, 算法无法找到正确的位姿, 对于表情和贴图也无法进行。



图 5.13 人脸双目立体视觉消融实验

5.4 本章小结

本章首先评估了对于一段连续视频帧，本文算法对其的高保真还原以及时域稳定，随后通过定性和定量分析了本文算法的优势，同时展示了本算法生成的资产对于重光照、切换视角、后期编辑的支持，最后通过消融实验证明了本文人脸表情空间计算、人脸双目立体视觉、三阶段可微渲染三个核心模块的重要性，从多个角度证明了这套基于可微渲染的双目视频驱动的人脸动画，有非常高的表情还原度，且生成的资产可以方便接入目前的工业化流程，有广阔的应用前景。

第6章 总结与展望

本文设计了一套生成高保真的人脸动画的方法，首先先通过采集重建的表情基生成高质量的绑定，之后利用双目视频进行驱动，并通过定性和定量分析证明了还原的人脸动画与原视频有极高的相似度，尤其是对于极端表情的还原以及细节神态的捕捉非常到位，生成的人脸动画资产可以切换视角、更换光照、后期编辑等，可以非常方便地融入目前的工业化制作流程并实时渲染，具有非常广阔的应用前景。

根据详细的实验和分析可知，本文生成的人脸动画拥有非常高的真实感和对原视频很高的还原度主要归因于以下三个方面：

第一，一套高质量的面部骨骼绑定。本文选择使用骨骼绑定的方式进行人脸动画，其相比于三维混合形状的驱动有更高的质量，同时借助 Metahuman 多层级的面部骨骼设计，可以非常好地还原人脸动画的各个细节，在使用本文提出的人脸表情空间解算后，该绑定还可以很好地贴合本人的特征，不仅可以用于面捕算法解算表情，还可以方便地由动画师或者用户制作表情。

第二，人脸双目立体视觉得到的深度信息。刚体变换的预测一直是不带显式标记点的人脸动画中一个比较难解决的问题，本文通过双目的配置，使用立体视觉的原理，获得了人脸各个几何点大致的深度信息，针对人脸这个图案相似且重复图案众多的匹配任务，本文基于目前效果领先的特征匹配网络，训练了一个效果出众的人脸双目匹配神经网络，其可以获得四千余组正确的匹配，利用这些匹配就可以准确的得到人脸的刚体变换。

第三，一个三阶段可微渲染的优化框架。本文可微渲染的方法同时优化表情系数和漫反射贴图，不仅避免了可微渲染由于皮肤状态与采集时的不同和存在的镜面反射而无法收敛，还将几何无法表示的皱纹等信息在贴图上得以还原，并充分利用了双目视角提供的信息，应用漫反射各向同性的性质，将光照进行解耦，对每帧优化了一张漫反射贴图，同时为考虑到镜面反射等各向异性材质，在优化完一轮漫反射贴图后，再优化了一张与视角相关的低分辨率光照贴图，随后再在此光照贴图基础上进一步优化漫反射贴图，生成结果对每一帧都有 PSNR 接近 38dB 的还原度，且支持切换视角和更换光照，此外，由于使用支持 MetaHuman 的绑定，得到的动画序列还可以进入 Maya 通过控制器滑块方便地进行后期编辑。

同时, 本文的算法仍有一些不足, 比如表情的解算不是实时的, 由于基于路径追踪的可微渲染每次迭代至少需要 0.1 秒, 而要做成实时面捕并渲染, 面捕的耗时最多只能在 0.01 秒每帧, 并且本文算法分了三阶段可微渲染, 还有人脸双目匹配, 使得每帧的耗时长达 1 秒, 这会导致难以应用在虚拟现实/增强现实应用中, 后期可以尝试使用该方法生成的高质量面捕数据训练一个神经网络, 直接使用网络端到端地进行表情系数和贴图的预测, 还可以选择结合最新的工作比如 3D Gaussian Splatting, 借优化 3D Gaussian Splatting 来同步优化多边形网格模型, 对可微渲染进行加速。同时, 本文生成的动画资产的重光照会有一些瑕疵, 这是因为生成的贴图不能很好地满足漫反射的全部特征, 并没有将光照信息全部解耦, 尤其是两个视角没有同时拍到的区域, 难以通过双目视频进行有效约束, 解决以上两点问题, 可以作为我未来的研究方向。

参考文献

- [1] Cao C, Agrawal V, De La Torre F, et al. Real-time 3D neural facial animation from binocular video[J]. ACM Transactions on Graphics (TOG), 2021, 40(4): 1-17.
- [2] Zielonka W, Bolkart T, Thies J. Towards metrical reconstruction of human faces[C]//European Conference on Computer Vision. Cham: Springer Nature Switzerland, 2022: 250-269.
- [3] Cao C, Weng Y, Lin S, et al. 3D shape regression for real-time facial animation[J]. ACM Transactions on Graphics (TOG), 2013, 32(4): 1-10.
- [4] Lewis J P, Anjyo K, Rhee T, et al. Practice and theory of blendshape facial models[J]. Eurographics (State of the Art Reports), 2014, 1(8): 2.
- [5] Carrigan E, Zell E, Guiard C, et al. Expression Packing: As-Few-As-Possible Training Expressions for Blendshape Transfer[C]//Computer Graphics Forum. 2020, 39(2): 219-233.
- [6] Yuille A, Kersten D. Vision as Bayesian inference: analysis by synthesis?[J]. Trends in Cognitive Sciences, 2006, 10(7): 301-308.
- [7] Mildenhall B, Srinivasan P P, Tancik M, et al. NeRF: Representing scenes as neural radiance fields for view synthesis[J]. Communications of the ACM, 2021, 65(1): 99-106.
- [8] Kerbl B, Kopanas G, Leimkühler T, et al. 3D Gaussian splatting for real-time radiance field rendering[J]. ACM Transactions on Graphics, 2023, 42(4): 139.
- [9] Sun J, Shen Z, Wang Y, et al. LoFTR: Detector-free local feature matching with transformers[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2021: 8922-8931.
- [10] Klehm O, Rousselle F, Papas M, et al. Recent advances in facial appearance capture[C]//Computer Graphics Forum. 2015, 34(2): 709-733.
- [11] Zollhöfer M, Thies J, Garrido P, et al. State of the art on monocular 3D face reconstruction, tracking, and applications[C]//Computer Graphics Forum. 2018, 37(2): 523-550.
- [12] Powell M J D. Numerical methods for nonlinear algebraic equations[M]. New

- York: Gordon and Breach, 1970.
- [13] Yang H, Zheng M, Feng W, et al. Towards practical capture of high-fidelity relightable avatars[C]//SIGGRAPH Asia 2023 Conference Papers. 2023: 1-11.
- [14] Lombardi S, Simon T, Schwartz G, et al. Mixture of volumetric primitives for efficient neural rendering[J]. ACM Transactions on Graphics (TOG), 2021, 40(4): 1-13.
- [15] Qian S, Kirschstein T, Schoneveld L, et al. Gaussianavatars: Photorealistic head avatars with rigged 3D Gaussians[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2024: 20299-20309.
- [16] Zielonka W, Bolkart T, Thies J. Instant volumetric head avatars[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. 2023: 4574-4584.
- [17] Li H, Yu J, Ye Y, et al. Realtime facial animation with on-the-fly correctives[J]. ACM Transactions on Graphics, 2013, 32(4): 42.
- [18] Weise T, Bouaziz S, Li H, et al. Realtime performance-based facial animation[J]. ACM Transactions on Graphics (TOG), 2011, 30(4): 1-10.
- [19] Beeler T, Bickel B, Beardsley P, et al. High-quality single-shot capture of facial geometry[C]//ACM SIGGRAPH 2010 Papers. 2010: 1-9.
- [20] 林丽皇, 陈俊. 多视图三维人脸重建方法研究[J]. 电视技术, 2022, 46(7): 203-207.
- [21] Beeler T, Hahn F, Bradley D, et al. High-quality passive facial performance capture using anchor frames[J]. ACM Transactions on Graphics, 2011, 30(4): 75.
- [22] 景晨凯, 宋涛, 庄雷, 等. 基于深度卷积神经网络的人脸识别技术综述[J]. 计算机应用与软件, 2018, 35(1): 223-231.
- [23] Zhang Z. Flexible camera calibration by viewing a plane from unknown orientations[C]//Proceedings of the Seventh IEEE International Conference on Computer Vision. IEEE, 1999, 1: 666-673.
- [24] Blanz V, Vetter T. A morphable model for the synthesis of 3D faces[C]//Seminal Graphics Papers: Pushing the Boundaries, Volume 2. 2023: 157-164.
- [25] Li T, Bolkart T, Black M J, et al. Learning a model of facial shape and expression from 4D scans[J]. ACM Transactions on Graphics, 2017, 36(6): 194.

- [26] Zhu Y, Omens D, He H, et al. Democratizing the creation of animatable facial avatars[J]. arXiv preprint arXiv:2401.16534, 2024.
- [27] Riviere J, Gotardo P F U, Bradley D, et al. Single-shot high-quality facial geometry and skin appearance capture[J]. ACM Transactions on Graphics, 2020, 39(4): 81.
- [28] Dib A, Bharaj G, Ahn J, et al. Practical face reconstruction via differentiable ray tracing[C]//Computer Graphics Forum. 2021, 40(2): 153-164.
- [29] Yu C, Gao C, Wang J, et al. BiSeNet v2: Bilateral network with guided aggregation for real-time semantic segmentation[J]. International Journal of Computer Vision, 2021, 129: 3051-3068.
- [30] Kingma D P. Adam: A method for stochastic optimization[J]. arXiv preprint arXiv:1412.6980, 2014.
- [31] Donner C, Jensen H W. A spectral BSSRDF for shading human skin[C]//Rendering Techniques. 2006: 409-418.
- [32] Riviere J, Gotardo P F U, Bradley D, et al. Single-shot high-quality facial geometry and skin appearance capture[J]. ACM Trans. Graph., 2020, 39(4): 81.
- [33] Dib A, Bharaj G, Ahn J, et al. Practical face reconstruction via differentiable ray tracing[C]//Computer Graphics Forum. 2021, 40(2): 153-164.
- [34] Pharr M, Jakob W, Humphreys G. Physically based rendering: From theory to implementation[M]. 3rd ed. Cambridge: MIT Press, 2023.
- [35] Wong T T. Image-based lighting[M]//Computer Vision: A Reference Guide. Cham: Springer International Publishing, 2021: 650-653.
- [36] Debevec P. Rendering synthetic objects into real scenes: Bridging traditional and image-based graphics with global illumination and high dynamic range photography[M]//Acm siggraph 2008 classes. 2008: 1-10.
- [37] Weise T, Bouaziz S, Li H, et al. Realtime performance-based facial animation[J]. ACM transactions on graphics (TOG), 2011, 30(4): 1-10.
- [38] Lewis J P, Cordner M, Fong N. Pose space deformation: a unified approach to shape interpolation and skeleton-driven deformation[C]//Seminal Graphics Papers: Pushing the Boundaries, Volume 2. 2023: 811-818.
- [39] Le B H, Deng Z. Smooth skinning decomposition with rigid bones[J]. ACM

- Transactions on Graphics (TOG), 2012, 31(6): 1-10.
- [40] Ma S, Weng Y, Shao T, et al. 3D Gaussian blendshapes for head avatar animation[C]//ACM SIGGRAPH 2024 Conference Papers. 2024: 1-10.
- [41] Amberg B, Romdhani S, Vetter T. Optimal step nonrigid ICP algorithms for surface registration[C]//2007 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2007: 1-8.
- [42] Floater M S. Mean value coordinates[J]. Computer Aided Geometric Design, 2003, 20(1): 19-27.
- [43] Numerical optimization[M]. New York: Springer New York, 1999.
- [44] Grishchenko I, Ablavatski A, Kartynnik Y, et al. Attention mesh: High-fidelity face mesh prediction in real-time[J]. arXiv preprint arXiv:2006.10962, 2020.
- [45] Baltrušaitis T, Robinson P, Morency L P. 3D constrained local model for rigid and non-rigid facial tracking[C]//2012 IEEE Conference on Computer Vision and Pattern Recognition. IEEE, 2012: 2610-2617.
- [46] Chai J, Xiao J, Hodgins J. Vision-based control of 3D facial animation[C]//Symposium on Computer Animation. 2003, 2.
- [47] Saragih J M, Lucey S, Cohn J F. Real-time avatar animation from a single image[C]//2011 IEEE International Conference on Automatic Face & Gesture Recognition (FG). IEEE, 2011: 117-124.
- [48] Wenger A, Gardner A, Tchou C, et al. Performance relighting and reflectance transformation with time-multiplexed illumination[J]. ACM Transactions on Graphics (TOG), 2005, 24(3): 756-764.
- [49] Nimier-David M, Vicini D, Zeltner T, et al. Mitsuba 2: A retargetable forward and inverse renderer[J]. ACM Transactions on Graphics (TOG), 2019, 38(6): 1-17.
- [50] Kim H, Zollhöfer M, Tewari A, et al. InverseFaceNet: Deep monocular inverse face rendering[C]//Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition. 2018: 4625-4634.
- [51] Tewari A, Zollhöfer M, Kim H, et al. MoFA: Model-based deep convolutional face autoencoder for unsupervised monocular reconstruction-supplemental material-[J].
- [52] Bharadwaj S, Zheng Y, Hilliges O, et al. Flare: Fast learning of animatable and

- relightable mesh avatars[J]. arXiv preprint arXiv:2310.17519, 2023.
- [53] Racković S, Soares C, Jakovetić D. Distributed solution of the inverse rig problem in blendshape facial animation[J]. arXiv preprint arXiv:2303.06370, 2023.
- [54] Chen Y L, Wu H T, Shi F, et al. Accurate and robust 3D facial capture using a single RGBD camera[C]//Proceedings of the IEEE International Conference on Computer Vision. 2013: 3615-3622.
- [55] Bouaziz S, Wang Y, Pauly M. Online modeling for realtime facial animation[J]. ACM Transactions on Graphics (TOG), 2013, 32(4): 1-10.
- [56] Cook R L, Torrance K E. A reflectance model for computer graphics[J]. ACM Transactions on Graphics (TOG), 1982, 1(1): 7-24.
- [57] Trowbridge T S, Reitz K P. Average irregularity representation of a rough surface for ray reflection[J]. Journal of the Optical Society of America, 1975, 65(5): 531-536.
- [58] Walter B, Marschner S R, Li H, et al. Microfacet models for refraction through rough surfaces[C]//Rendering Techniques. 2007: 18th.
- [59] Beckmann P, Spizzichino A. The scattering of electromagnetic waves from rough surfaces[M]. Norwood: Artech House, 1987.
- [60] Schlick C. An inexpensive BRDF model for physically-based rendering[C]//Computer Graphics Forum. Edinburgh: Blackwell Science Ltd, 1994, 13(3): 233-246.
- [61] ZHU Y, OMENS D, HE H, et al. Democratizing the creation of animatable facial avatars[J]. 2024.
- [62] 郝琮晖, 杜悠扬, 王璐, 等. 数字人脸渲染与外观恢复方法综述[J]. 中国图象图形学报, 2024, 29(9): 2513-2540.
- [63] 刘龙, 李浩生, 张梦璇, 等. 基于深度学习的人脸动画驱动方法综述[J]. 西安电子科技大学学报, 2025, 52(2): 57-84.
- [64] Epic Games. MetaHuman Animator[EB/OL]. (2023)[2024-07-20]. <https://www.unrealengine.com/metahuman>.

作者简历

教育经历:

2018.09 – 2022.06	东北大学
2022.09 – 至今	浙江大学

工作经历:

2022.07 – 2024.06	杭州相芯科技有限公司
2024.10 – 2024.12	腾讯科技（深圳）有限公司--光子工作室群

攻读学位期间发表的论文和完成的工作简历:

在杭州相芯科技有限公司工作期间，我主要负责了两个部分的工作。

动画部分：将 UE 没有开源的 **MetaHuman** 进行了完美复现，并配套完成了动画部分的美术制作流程平台和 **Maya** 插件

引擎部分：基于公司自研引擎，实现了 **MetaHuman** 及其实时渲染功能

在腾讯的光子工作室群技术发展部实习期间，我完成了三个工作。

工程部分：将高耦合的 **UEMetaHuman** 系统流程中所有预置内容格式（包括骨骼结构和模型布线等），完美适配光子自己的资产，并在光子工作室群正在开发的游戏中实现了应用。

科研部分：设计算法完成分层级人脸关节的逆解算，并手写 **CUDA** 加速的 **dogleg** 逆 **lbs** 最小二乘优化；基于 **transformer** 构建关节的高层级表示，成功减少了一半的数据采集量。

研二时，将成果发表了国家专利——《一种基于双目视频的面部表情高保真捕捉方法》，我为第一作者，导师为第二作者。

致谢

在我的研究生学习和毕业论文的撰写过程中，我得到了许多人的支持和帮助。在此，我想对所有给予我帮助的人表示最诚挚的感谢。

首先，我要感谢任老师，感谢您在我整个研究过程中提供的悉心指导和无私支持。当我刚刚踏入科研之门时，是您不厌其烦地教我正确的思考思路，还有吴老师、周老师各位实验室的老师，不仅在学术上给予我精心的指导，也在生活和职业发展上给予我宝贵的建议，您的严谨治学和探索精神深深感染了我，使我在学术道路上不断前行。

我要特别感谢研究生期间的朋友们。唐是我在工位并肩作战到深夜的伙伴，我们经常一起讨论问题、碰撞思路，在交流中总能激发出许多新颖的想法。常则是我身边不折不扣的科研大佬，拥有两篇顶会的实力，总是耐心解答我的疑问，给了我很多启发。以及各位实验室的同学们，你们在我学习和研究过程中给予了无私的帮助与鼓励，每一次讨论和交流都让我受益匪浅，通过讨论和思维的碰撞，我们也了解到了更多的领域，接触到了更多的知识，我们的友谊也让我在学术旅程中充满力量。

此外，感谢浙江大学的各位老师和同学们，感谢你们在这段时光中与我一同度过，分享学习和生活中的点滴，使我的研究生生涯更加丰富多彩。

最后，感谢我的家人，感谢你们一直以来的理解、支持和鼓励。尤其是我的父母，感谢你们无私的爱和耐心，让我能够无后顾之忧地投身于学术研究。你们的陪伴是我不断前进的动力源泉。

感谢所有曾给予我帮助的人，正是因为你们的支持和鼓励，我才能顺利完成学业并撰写此篇论文。未来的道路仍然充满挑战，我将不忘初心，继续努力。

于浙江大学软件学院

2025 年 4 月 3 日